

On-premise 폐쇄망 환경에서 SLLM-Advanced RAG 융합 시스템 구축방안에 관한 연구

고동희¹, 이창수¹, 박정준¹, 김진원¹

¹아레스

A Study on the Implementation Strategy of an SLLM-Advanced RAG Fusion System in On-Premise Closed Network

Dong-Hee Koh¹, Chang-Su Lee¹, Jung-Jun Park¹, Jin-Won Kim¹

¹Ares, Daejeon, Korea

요약 보안 및 운용 제약이 엄격한 온프레미스 폐쇄망 환경에서 군사 교리 지식에 특화된 질의응답 시스템을 구축하기 위해서는 데이터 보안 유지와 답변 정확성을 확보할 수 있는 고도화된 시스템 설계가 필요하다. 본 연구에서는 이를 위한 실질적인 기술적 방법론으로서 SLLM(Small Large Language Model)과 Advanced RAG의 최적화된 융합 모델을 제안한다. 실험을 위해 Mistral-7B, Qwen-2.5-7B, Llama-3.1-8B, GPT-OSS-20B와 같은 대표적인 SLLM 모델을 활용하였다. 또한 A6000 GPU, vLLM 추론엔진, FAISS DB를 기반으로 한 폐쇄망 환경을 구축하였으며, SLLM과 Naive-RAG를 결합하여 각 모델의 성능을 비교 분석한 후 최적의 기본 모델을 선정하였다. 특히, 쿼리 확장, 인덱스 최적화, 후처리 기법으로 대표되는 Advanced RAG 기법을 단계적으로 적용하는 실험 설계를 통해 검색 성능과 답변 품질에 미치는 영향을 추가로 분석하였다. 평가 데이터셋은 DeepEval 라이브러리를 활용하여 생성하였으며, 모델의 정량적·정성적 성능평가를 위해 RAGAS 평가지표, NLP 기반 메트릭, LLM-as-judge 방법을 함께 활용하였다. 실험 결과, Parent-Child 인덱싱과 쿼리 확장 및 상호 순위 융합(RRF) 후 처리를 결합한 구조가 가장 우수한 성능을 보임을 확인하였다. 이러한 연구 결과는 온프레미스 폐쇄망 환경에서도 SLLM과 Advanced RAG 기법의 효과적인 융합을 통해 안정적이고 신뢰성 높은 군 교리 특화 질의응답 시스템 구현이 가능함을 시사한다.

Abstract To build a high-performance military doctrine-specialized QA system in security- and resource-constrained on-premise environments, an advanced system architecture capable of ensuring both data security and response accuracy is required. To this end, we propose an optimized fusion model of SLLMs and Advanced RAG as a practical technical approach. For the experiment, representative SLLMs—such as Mistral-7B, Qwen-2.5-7B, Llama-3.1-8B, and GPT-OSS-20B—were utilized. In addition, an on-premise closed-network environment was established using an A6000 GPU, vLLM, and FAISS DB. Different SLLMs were combined with a Naive-RAG approach and comparatively evaluated to identify an optimal baseline model. Subsequently, Advanced RAG techniques—query optimization, index optimization, and post-processing—were incrementally applied to further analyze their impact on document retrieval performance and answer quality. The evaluation dataset was generated using the DeepEval library, and the model performance was evaluated via RAGAS, NLP-based metrics, and the LLM-as-judge approach. Experimental results showed that combining Parent-Child indexing with query expansion and RRF post-processing achieved the best performance. These findings suggest that the effective integration of SLLMs and Advanced RAG techniques enables the implementation of a stable and reliable military doctrine-specialized QA system, even in an on-premise closed network environment.

Keywords : On-premise, SLLM, Chatbot, Military Domain, Advanced Retrieval-Augmented Generation

*Corresponding Author : Dong-Hee Koh(Ares Co., Ltd.)

email: dannykoh@aresinfo.com

Received January 21, 2026 Revised February 23, 2026

Accepted ??? Published ???

1. 서론

LLM(Large Language Model) 기술은 지난 몇 년간 눈에 띄는 비약적인 발전을 이루어 왔다. Transformer 아키텍처 기반의 LLM 모델들은 Self-attention과 병렬 처리 구조를 도입함으로써 기존의 recurrent 및 encoder-decoder 아키텍처 기반 언어모델이 가진 문맥 처리 한계와 학습 효율, 규모 확장성 문제를 크게 개선하였다[1]. 이 후 수십억 개 이상의 매개변수를 가진 트랜스포머 모델의 학습이 기술적으로 가능해졌으며[2], 모델의 대규모화는 창발 능력(Emergent Abilities)의 발현을 통해 문맥 내 학습 (in-context learning), 지시 수행 능력(instruction following), 단계 추론(multi-step reasoning)과 같은 고급 추론 및 자연어 이해를 가능하게 하여 다양한 AI 응용 분야에서 새로운 가능성을 열었다[3].

아울러 LLM의 적용 범위는 의학, 법률, 금융 등 다양한 산업·도메인으로 빠르게 확장되고 있다. 의학 분야에서는 질의응답, 임상 정보 추출, 이상 상태 탐지, 의료 보고서 생성, 의료 영상 분류 등 여러 업무에서 LLM 기반 자동화가 적극적으로 이루어지고 있다[4]. 법률 분야에서도 질의응답, 판결 예측, 사건 탐지, 텍스트 분류, 문서 요약 등 다양한 분석·추론 작업에서 LLM이 실질적인 성과를 보이며 활용 영역을 넓혀가고 있다[4]. 금융 분야에서는 뉴스 기사, 애널리스트 보고서, 소셜 미디어 게시물 등을 활용해 시장 정서(sentiment)를 분석하거나[4], 이를 기반으로 주가 추세 및 시장 행동을 예측하려는 연구가 활발하게 진행되고 있다[5-6].

이와 함께 의료, 법, 금융 모든 분야에서는 개인정보 유출(privacy)위험을 해소하고 도메인 특화 성능을 확보하기 위해, 오픈소스 언어모델을 파인튜닝하여 오픈프래미스 환경에서 운용하려는 연구도 활발하게 이루어지고 있다. 의료 분야의 경우 Llama모델에 지속 사전학습과 지시 기반 미세조정 기법을 적용해 도메인 지식을 추가 학습시키고 의료 NLP 성능을 크게 향상시킨 사례가 대표적이다[7-8]. 금융 분야에서는 Bloomberg가 대규모 금융 문서를 활용하여 특화 모델을 개발한 사례가 있으며[9], 이 외에도 다양한 오픈소스 기반 금융 LLM을 구축하려는 시도가 보고되고 있다.

최근에는 멀티모달 LLM 연구도 더욱 확산되고 있다. 의료 분야에서는 X-ray, CT, MRI, ultrasound 등 다양한 의료 영상을 결합한 멀티모달(multi-modal) Medical LLM 연구가 활발히 진행되고 있으며 [10-11], 금융 분야에서도 표(tabular) 및 시계열(time-series) 데이터와 언어모델을 통합하려는 멀티모달 LLM 연구가 빠르게 증가하는 추세이다[12].

군 분야에서도 LLM 기술의 신속한 도입을 위한 노력이 활발하나[13-14], 데이터 최신성, 환각, 보안 등의 문제로 실무 적용에는 여러 한계가 있다[15-16]. 최근 이를 해결하기 위한 방안으로, 오픈프래미스 기반 SLLM과 RAG 기법 적용이 대안으로 논의되고는 있으나[14, 17], 복잡한 문서 구조와 엄격한 용어 정의를 가진 군사 도메인의 특성상 기초적인 RAG(Naive-RAG)만으로는 신뢰성 및 정확성 확보가 어렵다. 따라서 쿼리 최적화, 인덱싱 고도화, 후처리 등으로 대표되는 Advanced RAG 기법의 최적화 적용 전략이 필수적이다. 그럼에도 자원이 제한된 폐쇄망 환경에서 이러한 접근방법에 대한 실증적 영향과 최적의 조합에 관한 연구는 여전히 미진하다.

이에 본 연구는 보안 및 자원 제약이 엄격한 오픈프래미스 폐쇄망 환경에서 군사 전문 도메인 지식에 특화된 고성능 질의응답 시스템 구축 방법론을 제안하고자 하며, 이를 위해 다음과 같은 핵심 연구 질문(Research Question, RQ)을 실험적으로 검증하고자 한다.

RQ1: 군 폐쇄망 환경에서 RAG 기법의 단계적 고도화(No-RAG vs. Naive-RAG vs. Advanced RAG)가 SLLM의 군사 도메인 지식 검색 및 답변 생성 성능에 미치는 영향은 어떠한가?

RQ2: 군 교리 데이터의 특수성을 고려할 때, 어떠한 쿼리·인덱스 최적화 및 후처리 기법의 조합이 검색 정밀도와 답변 신뢰성 측면에서 최적인가?

본 연구는 이러한 질문에 답하기 위해 SLLM 기반의 시스템 아키텍처를 설계하고, 다차원 평가지표와 전용 데이터셋을 활용한 실험적 검증을 수행하고자 한다.

2. 이론적 배경

2.1 폐쇄망 보안 중심 환경에서 SLLM의 필요성

LLM 초기 발전은 GPT-3/4, Claude, Gemini 등 closed-source 모델이 주도하였으나[18-19], 최근에는 Mistral, Qwen 등 다양한 고성능 open-source 모델을 중심으로도 빠른 기술적 진보가 이루어지고 있다[12, 21]. Closed-source 모델은 우수한 성능에도 불구하고 투명성 부족과 민감 정보 유출위험, 제한적인 확장성 등으로 인해 특정 도메인 적용에 제약이 있다 [22]. 반면, open-source SLLM은 모델 수정이 용이하고 폐쇄망 내 직접 운영 및 튜닝이 가능하다는 보안상의 강점을 지닌다[22]. 특히 특정 도메인에 미세 조정된 경량 모델이 일부 closed-source 모델과 대등한 성능을 보인다는 사례는[23], 높은 보안성과 도메인 특화 확장성이 요구되는 군 환경에서 open-source 기반 SLLM이 효과적인 대안임을 뒷받침한다.

2.2 LLM의 한계와 개선 방안

범용 지식을 기반으로 학습된 LLM은[24] 최신 정보나 전문 지식이 요구되는 질문에 대해 사실과 다른 답변을 생성하는 환각(hallucination) 문제를 지니며 [25], 이러한 문제는 법률 및 의학 등 지식 집약적 도메인에서 현저하게 드러난다[26-28]. 이러한 한계를 극복하기 위해 RAG(Retrieval Augmented Generation), 모델 미세조정(fine-tuning), 프롬프트 설계(prompt engineering) 등이 활용되는데[29], 미세조정은 모델 내부 파라미터 수정을 통해 성능을 향상시키는 반면[30], RAG와 프롬프트 설계는 모델 구조 변경 없이, 외부 정보 연동 및 입력 문장의 전략적 설계를 통해 사용자 요구에 맞는 출력을 유도하는 방식이다[22, 30].

하지만 미세조정 경우 대규모 학습데이터 구축과 막대한 계산 자원을 요구하기 때문에 군사 도메인을 포함한 다양한 실제 응용 분야에서 적용하기에는 많은 제약이 따른다[24, 31]. 반면 RAG는 외부 데이터베이스의 특화 지식을 통합하여 환각 문제를 효과적으로 감소시킬 수 있으며[24], 최근에는 미세조정 방식보다 완전히 새로운 정보에 대해 더 우수한 성능을 보인다는 연구 결과도 보고되었다[32-33]. 따라서 보안성과 자원 효율성이 중시되는 군사 도메인에서는 미세조정 없이 RAG와 프롬프트 설계만으로 시스템을 구축하는 것이

실질적이고 합리적인 대안이 될 수 있다.

2.3 Advanced RAG

RAG기법은 Lewis 등[34]의 제안 이후 다양한 방식으로 발전해 왔으며, 그 초기 형태인 Naive-RAG는 문서 색인, 검색, 생성으로 구성된 “Retrieve-Read” 구조를 따른다[35]. 이는 원본 텍스트를 청크 단위로 분할·임베딩한 뒤 유사도 기반 검색을 통해 관련 문서를 추출하고, 이를 사용자의 질문과 결합하여 LLM의 응답을 유도하는 방식이다(Fig. 1)[29]. 그러나 Naive-RAG는 검색 정밀도의 한계, 비효율적 문서 분할, 불완전한 문맥 연결 등 구조적인 한계를 지닌다[29]. 이에 따라 최근에는 이러한 한계를 보완하기 위한 다양한 Advanced RAG 기법들이 활발히 연구되고 있다.




Fig. 1. Naive-RAG vs. Advanced RAG: Elements highlighted in pink represent Advanced RAG components, while those in green denotes Naive-RAG components

Advanced RAG는 Fig. 1과 같이, Naive-RAG의 구조를 개선하여 검색 정확도와 문맥 활용 능력을 체계적으로 향상시키는 방식이다. 이를 위해 검색 전 단계에서는 세분화된 텍스트 분할, 키워드·요약·가상 질의 기반 메타데이터 구축, 고급 인덱스 구조 설계 등을 통해 더욱 풍부한 문맥을 검색하고 정밀도를 높인다 [29]. 또한 사용자의 쿼리를 재작성하거나 확장하는 등의 방식으로 질문을 Vector DB에 최적화된 형태로 변환한다[35, 36]. 이어지는 검색 후(Post-retrieval) 단계에서는 재랭킹(Re-ranking) 및 문맥 압축을 통해 검색된 정보를 정제한다. 이는 정보 과부하로 인한 답변 품질 저하를 방지하고 핵심 정보를 선별하여 생성된 답변의 품질을 높이는 데 목적이 있다[29].

결과적으로 Advanced RAG는 전·후처리 기반의 최적화 전략을 통해 Naive-RAG의 한계를 보완하며, 군

교리·교범처럼 복잡하고 다층적인 문서 구조에서도 높은 적용 가능성을 보인다. 본 연구는 이러한 특성을 고려하여 Advanced RAG 기반의 시스템을 설계하였으며, 구현을 위해 다양한 개발 프레임워크 중 하나인 LangChain 라이브러리를 활용하였다[37].

2.4 군사 도메인에서의 LLM 활용

국방 분야에서도 LLM 도입을 위한 다양한 시도와 연구가 활발히 이루어지고 있다. 특히 한국의 경우 출산율 급감에 따른 병력 자원 부족이 심화되고, 현대 전장의 복잡성과 무기체계의 고도화로 인해 적은 인력으로 더 높은 전투력과 운용 효율을 달성해야 하는 현실에 직면하고 있다[13]. 이러한 배경에서 한국 군도 LLM 기반 AI 기술을 지휘 결심 보조, 교육훈련, 데이터 분석 자동화, 문서 분석·보고서 생성, 전장 상황 인식 등 다양한 분야에 적용해 전투 수행 능력 향상과 운영 효율 극대화 방안을 적극 모색하고 있다[14].

일례로, 최근 국방부는 국방 특화 생성형 AI 모델인 GeDAI(Generative Defense AI)를 공개하며 LLM 기반 AI 기술 도입을 본격화하고 있다. 보안을 위해 이 시스템은 외부 인터넷과 분리된 국방 내부망에 구축되었으며, 인사관리, 재정 지원, 문서 요약, 음성 분석 등의 기능을 국방부 직원들에게 제공하고 있다[13]. 또한 GeDAI는 제한된 인프라 환경과 군 도메인의 특성을 고려해 경량화된 SLLM을 기반으로 설계·구현되었다[38]. 또 다른 사례로, 최근 연구[17]에서는 실시간 전장 상황 분석을 위해 RAG와 Supervised Fine-Tuning(SFT)을 융합한 LLM 기반 시스템을 제안하였다. 연구팀은 군 전문가와 협업해 구축한 합성 전장 데이터를 활용하여 환각(hallucination)과 중간 정보 손실 문제를 완화할 수 있는 Triple-structured SFT 전략을 적용하였으며, 그 결과 소규모 언어모델(Llama-3.1-8B)이 대규모 언어모델(Llama-3.1-405B)을 상회하는 성능을 보임으로써 군사 환경에서 SLLM의 실용적 적용 가능성을 확인하였다.

이와 더불어 국방 분야에서는 지휘통제 지휘결심(C2) 지원 영역에서도 LLM 적용 연구가 활발히 이루어지고 있다. 대표적으로 미 육군 DEVCOM은 군사 결심 과정의 속도와 품질을 향상시키기 위해 COA-GPT 2.0으로 불리는 LLM 기반 계획 지원 체계를

개발 중이다[39]. 이 시스템은 멀티모달 LLM, 특화된 외부 도구, 군 전문가의 판단을 융합하여 지휘 참모단이 방책을 신속히 생성·평가할 수 있도록 지원한다. DEVCOM은 이를 통해 시간이 제한된 의사 결정 상황에서도 지휘 결심 우위를 유지하고 변화하는 전장 상황에 민첩하게 대응할 수 있는 능력을 확보하는 것을 목표로 한다.

최근 연구에서는 공개된 미군 교리·교범 자료를 활용하여 군 특화 소규모 언어모델을 구축한 사례도 보고되었다[40]. 연구팀은 범용 LLM을 그대로 적용할 경우 도메인 특화 성능이 부족하다는 점을 지적하며, 이를 해결하기 위해 Fine-tuning 파이프라인을 지속적으로 개선하여 여러 세대의 TRACLM 모델을 순차적으로 개발하였다. 아울러 모델의 군사 도메인 지식을 객관적으로 측정하기 위해 교범 기반 평가 과업을 활용하는 MilBench 프레임워크도 함께 제안하였다. 실험 결과 TRACLM은 세대가 거듭될수록 군사 과업 및 여러 활용 사례에서 성능이 지속적으로 개선되는 결과를 보였으며, 이는 국방 도메인 특화 SLLM의 실용적 활용 가능성을 뒷받침한다.

지금까지 살펴본 바와 같이 LLM 기반 AI 기술은 전장 상황 분석, 지휘 결심 보조, 행정 업무 지원 등 다양한 군사 영역으로 빠르게 확산되고 있으며, 실효성 있는 시스템 개발을 위해서는 최신 기술의 체계적인 반영이 요구되는 시점이다. 이에 제3장에서는 앞서 논의한 이론적 배경과 기술적 제약 사항을 바탕으로, 군 폐쇄망 환경에 최적화된 질의응답 시스템 구축을 위한 시스템 설계 및 실험 방안을 기술하고자 한다.

우선 2.1과 2.2에서 강조된 보안 및 자원 효율성을 고려하여 실험에 사용된 SLLM의 선정 사유를 밝히고, 군사 교리 데이터를 활용한 데이터셋 생성 방안을 구체적으로 논의한다. 이어 2.3절에서 지적인 Naive-RAG의 한계를 극복하기 위한 대안으로 쿼리 최적화, 인덱스 최적화, 후처리 기법으로 구성된 Advanced RAG 아키텍처의 구체적인 구현 방안을 제안한다. 마지막으로 2.4절의 군사 도메인 특수성을 반영하여, RAGAS 등 다각적인 평가지표를 통해 시스템의 신뢰성과 실용성을 검증할 수 있는 절차를 논의한다. 이러한 체계적인 설계 및 실험 방안은 폐쇄망 환경에서도 안정적으로 운영 가능한 군 특화 지식

서비스 구현을 위한 방법론적 토대가 된다.

3. 데이터 및 연구 방법론

3.1 실험 데이터셋

본 연구에서는 군사 도메인에 특화된 질의응답 시스템을 개발하기 위해 미 육군 공개 아카이브에서 제공되는 기밀 해제·일반 공개용 교리·교범 문서를 데이터로 활용하였다. 이 중 국내 안보 환경과의 연관성이 높은 North Korean Tactics 교리를 평가용 실험 데이터로 선정하였으며, 해당 문서는 총 342쪽 분량으로 9개의 장과 9개의 부록으로 구성되어 있다. 또한 효율적인 LLM-RAGOps(RAG Operations) 파이프라인 구축을 위해 DeepEval 라이브러리를 사용하여 합성 데이터셋을 구축하였다. DeepEval은 정량·정성적 평가지표 제공과 합성 데이터 생성 기능을 포함한 오픈소스 프레임워크로, LLM 기반 애플리케이션 개발의 전반적인 과정을 자동화하는데 유용하다.




Fig. 2. Dataset generation process using DeepEval library

Fig. 2는 DeepEval을 활용한 합성 데이터 생성 파이프라인을 나타낸다. 먼저 원본 문서를 입력하면, 사전에 정의한 청크 크기(chunk-size=1024)에 따라 문서가 분할되고, 각 청크는 임베딩으로 변환된 뒤 리스트 형태로 저장된다. 이후 평가용 질의 생성을 위한 기준 문서(reference document)가 무작위로 선택되며, 코사인 유사도 기반 검색을 통해 관련성이 높은 추가 문맥을 추출하여 문맥 집합을 구성한다. 이는 질문 생성 시 보다 풍부한 문맥과 고차원적 추론을 요구하는 질의를 생성하기 위한 전처리 단계이다. 다음으로 선택된 문맥을 기반으로 LLM을 통해 질의를 생성하고, 생성된 질의는 Evolver 모듈을 통해 다양한 난이도와 복잡성을 갖도록 진화과정을 거친다. 마지막으로 LLM에 선택된 문맥과 변형된 질의를 입력하여 기대 응답(expected output)을 생성함으로써 합성 데이터셋을 완성한다. 생성된 데이터는 연구자의 검토를 통해 품질과 일관성을 확인한 뒤, 총 69개

의 평가 데이터 항목을 최종적으로 선정하였다. 다만, 본 연구에서 구축된 데이터셋은 군사 전문가에 의한 다각적인 교차 검증 과정을 거치지 못했다는 점과 방대한 군사 교리 전체를 대표하기에는 표본의 크기가 제한적이라는 한계가 있다. 따라서 본 데이터를 기반으로 한 실험 결과는 특정 교범 범위 내에서의 RAG 파이프라인 효용성을 검증하기 위한 기초 연구로 해석되어야 한다.

3.2 환경 구성

Table 1. Hyperparameter configurations for experiment

Category	Hyperparameter	Value
Retrieval	Top-k	4
Decoding	Temperature	0.2
	Top-p	0.9
Window	Max context token	40,960
	Max input token	34,960
	Max output token	6,000
Prompt	Prompt template	[instruction] + [context] + [query]

온프레미스 폐쇄망 환경 구성을 위해 NVIDIA A6000 GPU를 사용하였다. A6000은 Ampere 아키텍처 기반의 고성능 GPU로, 48GB VRAM을 갖추고 있어 소규모(10B 미만) LLM은 물론, 양자화된 중간 규모(약 20B ~ 30B) LLM 운영에도 충분한 연산 자원을 제공한다. LLM 기반 시스템 환경을 구축하기 위해서는 GPU 선택뿐 아니라, 해당 하드웨어 성능을 최적화하여 활용할 수 있도록 지원하는 추론 엔진(inference engine)의 선정 또한 중요하다. 일반적으로 널리 사용되는 llama.cpp 계열의 llamafile, Ollama, Gpt4All, LM Studio 등은 사용자 친화성과 다양한 오픈소스 양자화(quantized) 모델의 로컬 실행을 지원한다는 장점이 있으나, 비양자화(non-quantized) LLM을 고성능 GPU에서 안정적으로 구동하여 실서비스급 환경을 구성하기에는 여러 제약이 존재한다. 이에 반해, vLLM 추론엔진은 고성능 GPU 기반 초고속 추론, 효율적인 메모리 관리(paged attention), 동적 배치(continuous batching), 다중 GPU 병렬 처리(tensor parallelism), 스트리밍 출력 등 생산 환경에서 요구되는 다양한 기능을 제공하기 때문에 상용 수준의 LLM 시스템 구축에 적합하다 [22]. 이러한 이유로 본 연구에서는 vLLM 추론엔진

기반 아키텍처를 설계하였다. 또한 효율적인 데이터 검색 및 생성을 위하여 GPU 가속화와 대규모 벡터 데이터셋 구축을 지원하는 FAISS(Facebook AI Similarity Search)를 데이터베이스로 활용하였다. 본 실험에서 최적의 추론 성능을 확보하기 위해 설정한 핵심 파라미터는 Table 1과 같다. Table 1에 명시된 바와 같이, Temperature를 0.2, Top-p를 0.9로 설정하여 모델의 무작위성을 억제하고 일관된 답변 생성을 유도하였다. RAG 파이프라인에서는 검색된 상위 4개의 컨텍스트 (Top-k=4)를 활용하도록 하였으며, 방대한 교범 데이터 내용을 충분히 반영할 수 있도록 전체 컨텍스트 (max context token) 길이를 40,960 토큰으로 설정하였다. 답변 생성 길이(max output token)는 6,000으로 할당하고, 이에 따라 가용한 최대 입력 길이(max input token)를 34,960토큰으로 구성하여 긴 문맥의 질의 처리 시 발생할 수 있는 정보 누락을 최소화하고자 하였다. 프롬프트 템플릿은 모델이 제공된 컨텍스트에 엄격히 입각하여 답변하도록 설계되었으며, 사실 왜곡을 최소화하고 환각을 방지하기 위한 제약 조건을 포함하였다.

3.3 실험에 사용된 LLM 선정 이유

본 연구에서는 다양한 규모의 LLM 성능을 비교하고 군사 도메인에 가장 적합한 모델을 선정하기 위해 Mistral-7B, Qwen-2.5-7B, Llama-3.1-8B, GPT-OSS-20B를 실험군 모델로 선정하였다. 이들 모델은 모두 오픈소스 기반으로, 경량 파라미터 대비 우수한 언어 이해 성능을 보이며 재학습 및 미세조정이 용이하다는 점에서 다양한 도메인 분야에서 활용 사례가 증가하고 있다. 또한 모든 모델은 앞서 언급한 vLLM 환경에서 안정적으로 구동이 가능하며, RAG기반 아키텍처 적용 시 성능 향상 여부를 관찰하기에 적합하다는 점에서 실험군 모델로 선정되었다. 아울러 소규모 모델에 RAG를 적용했을 때의 성능 개선 효과를 정량적으로 검증하고 이를 대규모 모델과 벤치마킹하기 위해, 상용 수준의 성능을 보이는 GPT-OSS-120B 모델과 Llama-405B 모델을 비교군으로 포함하여 상호 비교 실험을 수행하였다.

3.4 RAGS 기반 LLM 성능평가

LLM-RAG 기반 시스템의 평가는 검색(retrieve)과

생성(generation) 품질 평가를 중심으로 이루어진다. 본 연구에서 활용한 RAGS(Retrieval Augmented Generation Assessment) 프레임워크는 이러한 평가를 컨텍스트 관련성(context relevance), 답변 진실성(answer faithfulness, groundedness), 답변 관련성(answer relevance)의 세 가지 관점에서 측정한다[41]. 먼저, 컨텍스트 관련성은 Vector DB에서 관련 정보가 얼마나 정확하게(precision) 그리고 얼마나 빠짐없이(recall) 검색되었는지를 측정한다. Context Precision(CP)은 주어진 질의에 대해 검색된 컨텍스트 내에서 관련 문서가 얼마나 상위에 위치하는지를 측정하며 분석에 사용된 수식은 Eq. (1) (2)와 같다.

$$CP@K = \frac{\sum_{k=1}^K (Pre@k \times v_k)}{R_K} \quad (1)$$

$$Pre@k = \frac{TP@k}{TP@k + FP@k} \quad (2)$$

Where, K denotes the total number of retrieved chunks in the context, $v_k \in \{0,1\}$ indicates whether the chunk at rank K is relevant(1 if relevant, 0 otherwise), R_K denotes the number of relevant items within the top-K retrieved results, TP denotes true positives, where as FP indicates false positives.

컨텍스트 리콜(context recall)은 질의와 관련된 문서 가운데, 검색기가 실제로 얼마나 많이 찾아냈는지를 평가하는 지표이며, recall 값이 높을수록 검색 과정에서 누락된 문서가 적다는 의미로 해석할 수 있다. Context Recall을 계산하는 공식은 Eq. (3)과 같다.

$$Recall = \frac{TP}{TP + FN} \quad (3)$$

Where, TP and FN denote true positives and false negatives, respectively.

Context Precision과 Context Recall은 검색 품질을 서로 다른 관점에서 평가하기 때문에, 본 연구에서는 두 지표를 균형 있게 통합하여 측정하기 위한 지표로 F1-score를 함께 사용하였다. F1-score는 Precision과 Recall의 조화 평균(harmonic mean)으로, RAG 시스템 검색 성능을 종합적으로 평가할 수 있는 대표적인 척도이다. 계산식은 Eq. (4)와 같다.

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (4)$$

답변 진실성(Faithfulness)은 생성된 응답이 검색된 문맥과 사실적으로 얼마나 일관되는지를 평가하는 지표이다. 이 값이 높을수록 생성된 답변의 사실적 정확성이 우수함을 의미하며, 본 연구에서는 이를 모델의 환각 발생 여부를 진단하는데 활용하였다. 계산식은 Eq. (5)와 같다.

$$Faithfulness = \frac{|V|}{|S|} \quad (5)$$

Where, V denotes the number of claims in the response that are supported by the retrieved context and S denotes the total number of claims contained in the response.

마지막으로 답변 관련성(answer relevancy)은 생성된 답변이 질문과 얼마나 밀접하게 관련되었는지를 측정한다. 다시 말해, 불완전하거나 불필요한 정보를 포함한 답변은 낮은 점수를 받으며, 질문과 관련성이 높은 답변일수록 높은 점수가 계산된다. 답변 관련성은 먼저 모델에 의해 생성된 답변을 기반으로 n 개의 잠재적 질문을 역추론(reverse-engineered)하여 생성하도록 한다. 그리고 생성된 질문들과 원래 질문 사이의 코사인 유사도 평균값을 기반으로 최종 점수가 계산된다. Answer Relevancy(AR) 계산 공식은 Eq. (6)와 같다.

$$AR = \frac{1}{N} \sum_{i=1}^N \frac{E_{gi} \cdot E_o}{\|E_{gi}\| \|E_o\|} \quad (6)$$

Where, E_{gi} represents the embedding vector of the i -th generated question, E_o denotes the embedding vector of the original question, and N is the number of generated questions(set to 3 by default).

3.5 추가 성능평가 지표

그러나 RAGAS에서 제공하는 답변 관련성(answer relevance) 지표는 생성된 답변과 정답(reference)간의 직접적인 정확성을 평가하기보다는, 질문과 생성된 답변 간의 연관성에 초점을 두기 때문에 답변 자체의 내용적 품질을 충분히 평가하기에는 한계가 있다. 이러한 점을 보완하기 위하여, 본 연구에서는 다양한 자연어처리(Natural Language Processing) 분야에서 널리 사용되는 평가 지표인 BLEU, ROUGE-1, ROUGE-2, ROUGE-L, BERT F1 지표를 추가적으로 활용하여 생성된 답변의

품질을 보다 다방면에서 평가하고자 하였다.

BLEU(Bilingual Evaluation Understudy)는 생성 답변과 참조 답변 간 정확도를 평가하며, ROUGE(Recall-Oriented Understudy for Gisting Evaluation)는 생성된 텍스트와 참조 텍스트 간 일치도를 측정한다. 특히 ROUGE-n은 n -그램 기반의 일치율, ROUGE-L은 가장 긴 공통부분(LCS-Longest Common Subsequence)을 기준으로 답변 품질을 평가한다. BERTScore는 의미적 유사성에 초점을 두고, 코사인 유사도를 기반으로 측정되는 지표이다.

Table 2. LLM-as-judge evaluation metrics and explanations

Metrics	Explanation
Accuracy	Fact alignment with the ground truth (0~10)
Completeness	Coverage of all essential information (0~10)
Coherence & Reasoning	Logical structure and clarity of explanation (0~10)
Expression & Precision	Use of professional terminology and technical precision (0~10)
Qualitative Explanation	A brief summary (1-2 sentences) justifying the assigned scores

다차원적인 평가를 위하여 NLP기반 평가지표를 포함하였으나, 이러한 지표들은 의미적으로 올바른 답변이라도 표현 방식이 다르다는 이유만으로 과도하게 패널티를 주는 경향이 있다. 실제로 여러 연구에서 RAGAS 점수가 높은 경우에도 BLEU나 ROUGE 점수가 낮게 나타나는 사례가 보고되었으며, 이는 표면적 유사도 기반 지표의 한계를 보여준다[42]. 따라서 본 연구에서는 보다 종합적이고 정성적인 답변 품질 평가를 위해 LLM-as-judge(LLM 판정자) 방식을 적용하여 추가 평가를 수행하였으며, 이를 위해 OpenAI GPT-4.1 모델을 활용하였다. 생성 답변 평가에 사용된 구체적 기준은 Table 2에 요약되어 있다. 모델의 최종 성능 점수는 네 가지 정량적 지표의 평균값으로 산출되었으며, GPT를 활용해 생성된 정성적 평가 코멘트는 모델별로 요약하여 각 모델의 생성 답변을 정성적으로 비교 평가하는데 활용하였다.

3.6 고급 인덱싱

본 연구에서 적용한 Advanced RAG 기법은 크게 쿼리 최적화(query optimization), 인덱싱 최적화(Index Optimization), 그리고 후처리(Post-retrieval

processing)의 세 범주로 구성된다.

3.6.1 쿼리 최적화

먼저 검색 전 처리 단계(pre-retrieval)에서 수행되는 쿼리 최적화는 사용자의 입력 질의를 벡터 데이터베이스 검색에 보다 적합한 형태로 변환하는 것을 목표로 하며, 대표적인 기법으로는 쿼리 확장(query expansion, Eq.(8))과 쿼리 재작성(query rewrite, Eq.(9))이 있다. 쿼리 확장은 사용자의 질문이 복잡하거나 암묵적인 하위 질의를 포함하는 경우, 원 질의를 여러 개의 명시적 하위 질문으로 분해하는 방식이다. 생성된 각 하위 질문은 Eq. (8) Expansion에서와 같이 독립적으로 벡터스토어 검색에 사용된다.

$$f_{trans}(Q) = \begin{cases} q_1, q_2, \dots, q_m \\ \tilde{q} \end{cases} \quad (7)$$

$$Expansion \rightarrow \begin{cases} R_i = TopK(sim(\epsilon(q_i), \epsilon(C)), K) \\ R = \bigcup_{i=1}^m R_i \end{cases} \quad (8)$$

$$Rewrite \rightarrow R = TopK(sim(\epsilon(\tilde{q}), \epsilon(C)), K) \quad (9)$$

$$\hat{a} = G(\Pi(Q, R)) \quad (10)$$

Where, Q represents the original user query, and f_{trans} denotes the query transformation function that performs both query expansion and rewriting, q_i denotes an individual expanded query from query expansion and $\tilde{q}$ denotes a single re-written query resulting from query rewriting, sim refers to similarity search function based on cosine similarity, while ϵ represents embedding vector, C signifies the entire set of chunks constituting the database. R represents the final set of retrieved results, $\hat{a}$ denotes the final generated answer, Π indicate a prompt structure, and G represents the LLM-based generator.

반면, 쿼리 재작성 기법은 사용자의 질문을 벡터 데이터 기반 검색에 최적화 되도록 재작성(Eq. (9) rewrite) 한 후 검색 정확도를 향상시키는 방법이다. 즉, Naive-RAG가 Retrieve-and-Read 방식으로 원 질문을 그대로 LLM에 전달하는 데 반해, Advanced RAG는 쿼리 최적화 과정을 추가한 Rewrite-Retrieve-Read 워크플로우를 통해 검색 성능과 최종 응답 품질을 향상시킨다. Eq. (8),(9)에서 보여지는 바와 같이 최적화된 쿼리는 유사도 검색

을 통해 관련 문서를 먼저 검색한 후, 프롬프트로 구성되고 최종 답변 생성(Eq. (10))에 사용된다.

3.6.2 인덱스 최적화

또한 Advanced RAG는 인덱스 최적화 기법을 적용하여 벡터스토어의 검색 효율과 정확도를 향상시킨다. 본 연구에서는 이러한 인덱스 최적화 기법을 청크 최적화(chunk optimization), 메타데이터 고도화(metadata enhancement), 인덱스 구조 설계(index structure design)의 세 범주로 구분하여 적용하였다.

청크 최적화(Chunk optimization): 청크 최적화는 사용 목적에 부합하도록 원본 문서를 하위 청크로 분할함으로써 문맥 정보의 활용도를 높이고, 동시에 불필요한 정보(noise)의 유입을 최소화하여 검색 효율성과 정확도를 향상시키는 방법이다. 본 연구에서는 세분화된 청크 확장(granular chunk expansion)기법을 적용하였으며, 이는 문서를 문장 또는 문단 단위와 같이 세분화된 수준으로 분할한 후(Eq. (11)), 사용자의 쿼리와 관련된 청크가 검색되면(Eq. (12)) 해당 청크와 인접한 전후 청크를 함께 검색하여(Eq. (13)) 보다 정확하고 풍부한 문맥 기반 검색을 가능하게 한다.

$$D \rightarrow C = \{c_1, c_2, \dots, c_N\} \quad (11)$$

$$R = TopK(sim(\epsilon(q), \epsilon(C)), K) \quad (12)$$

$$C_{expanded} = \bigcup_{i \in R} \{c_{i-k}, c_i, c_{i+k}\}, k=1 \quad (13)$$

Where, D represents the input documents, c_i denotes individual chunk, and the other symbols are defined as in Eq. (8)(9).

메타데이터 고도화(metadata enhancement): 메타데이터 고도화는 검색 정확도를 향상시키기 위한 핵심적인 인덱스 최적화 기법이다. 본 연구에서는 문서 요약 임베딩과 가상 질문 임베딩을 메타데이터로 활용하는 검색 구조를 활용하였다. 먼저 요약 임베딩은 원본 문서를 하위 청크로 분할한 후(Eq. (14)), 각 청크에 대해 요약문을 생성한다(Eq. (15)). 이 후 생성된 요약문 임베딩을 기반으로 유사도 검색을 수행하며(Eq. (16)), 해당 과정에서 검색된

요약문과 연관된 원본 청크를 최종 검색 결과로 반환한다(Eq. (17)). 이러한 요약문 임베딩은 각 청크의 핵심 정보를 압축적으로 반영함으로써 불필요한 노이즈를 줄이고 전반적인 검색 정밀도를 향상시키는 데 기여할 수 있다.

$$D \rightarrow C = \{c_1, c_2, \dots, c_N\} \quad (14)$$

$$s_i = f_{sum}(c_i) \\ S = \{s_1, s_2, \dots, s_N\} \quad (15)$$

$$R = TopK(sim(\epsilon(q), \epsilon(S)), K) \quad (16)$$

$$C_{sum} = \{c_i | i \in R\} \quad (17)$$

Where, f_{sum} represents the summary function, S represents the set of summarized chunks, and all other symbols follow the definitions given above.

$$q_{ij} = f_{hq}(c_i), j = 1, 2, \dots, M \\ hq_i = \{q_{i1}, q_{i2}, \dots, q_{iM}\} \quad (18)$$

$$Q = \bigcup_{i=1}^N hq_i \quad (19)$$

$$R = TopK(sim(\epsilon(q), \epsilon(Q)), K) \quad (20)$$

$$C_{hq} = \{c_i | i \in R\} \quad (21)$$

Where, f_{hq} represents a hypothetical question function, hq_i denotes the set of generated hypothetical questions, and the remaining symbols are same as defined previously.

가상 질문 임베딩은 언어 모델을 활용하여 각 청크가 답변할 수 있을 것으로 예상되는 가상의 질문들을 먼저 생성하고(Eq. (18)), 이를 메타데이터로 추가하여(Eq. (19)) 유사도 기반 검색을 수행하는 방식이다(Eq. (20)). 이 과정에서 검색된 질문과 의미적으로 연관성이 큰 원본 청크가 검색 결과로 반환되며(Eq. (21)), 이는 최종 답변 생성에 활용된다. 이러한 접근은 의미적 연관성이 높은 청크를 보다 효과적으로 식별하도록 하여 검색 정확도를 향상시킬 수 있다.

인덱스 구조 설계(index structure design): 인덱스 구조 설계는 지식 베이스 내 문서 구조를 개선하여 검색 성능을 향상시키는 인덱스 최적화 기법이며, 본 연구에서는 부모-자식 문서 구조(Parent-child document structure)를 사용하였다. 구체적으로, 부모-자식 문서 구조는 문서를 계층적으로 분할 저장하는 방식으로 구현된다. 먼저 원본 문서는 비교적 큰 단위의 상위 청크로 분할된 후

$$D \rightarrow P = \{p_1, p_2, \dots, p_N\} \quad (22)$$

$$p_j \rightarrow C_j = \{c_{j1}, c_{j2}, \dots, c_{jM}\} \quad (23)$$

$$C = \bigcup_{j=1}^N C_j \quad (24)$$

$$R = TopK(sim(\epsilon(q), \epsilon(C)), K) \quad (25)$$

$$P_{retrieved} = \{p_i | \exists c_{jk} \in R\} \quad (26)$$

Where, p_i denotes an individual parent chunk, P denotes the set of parent chunks, c_{ji} denotes the first chunk of the j -th parent chunk, C represents the set of all child chunks, and the remaining symbols are same as defined previously.

(Eq. (22)), 다시 세부 내용을 담은 하위 청크(자식 문서)로 세분화되어 별도의 문서 단위로 저장된다(Eq. (23)). 검색 단계에서는 우선 사용자의 질의와 가장 높은 관련성을 갖는 자식 문서를 식별하고(Eq. (24)(25)) 자식 문서가 속한 부모 문서를 최종적으로 참조하도록 하여 추가적인 문맥 정보를 확보한다(Eq. (26)). 이러한 계층적 문서 구조는 세부 정보 수준에서의 검색 정밀도를 유지하면서도, 상위 문서를 통해 보다 넓은 문맥을 함께 제공할 수 있는 장점을 가진다.

3.6.3 후처리(Post Retrieval Processing)

지금까지 설명한 다양한 고급 RAG 기법을 적용하더라도, 검색 결과에는 중복 정보나 비관련 내용 등 여전히 상당한 노이즈가 포함될 수 있으며, 이는 LLM의 효과적인 정보 처리를 방해할 수 있다. 따라서 최적의 답변 생성을 위해서는 검색된 문서를 LLM에 전달하기 전에 관련성이 낮은 결과를 제거할 수 있는 검색 후(post-retrieval) 처리 단계가 필요하다. 이러한 후처리 과정은 LLM에 보다 정제된 문맥만을 제공함으로써 최종 답변의 품질을 향상시키는데 기여한다.

$$RRF_{score} = \frac{1}{rank + k} \quad (27)$$

Where, RRF_{score} denotes the reciprocal rank fusion score, $rank$ denotes the rank position of the i -th document in an individual ranked list, k is a smoothing constant to control the weight of existing ranks.

이에 본 연구에서는 상호 순위 융합(Reciprocal Rank Fusion, RRF) 기반의 후처리 기법을 적용하였다. 아래 Fig 4.에 묘사된 바와 같이, 사용자의 원 질의는 쿼리 확장 기




Fig. 3. Overview of the experimental framework and workflow

법을 통해 여러 개의 하위 질의로 변환되며, 각 하위 질의는 벡터 스토어로부터 개별적인 검색 결과 집합을 반환한다. 이후 모든 검색 결과는 RRF 점수(Eq. (27))를 기준으로 재정렬되며, 상위 결과들만 LLM에 전달되어 최종 답변 생성에 활용된다.




Fig. 4. Overview of the RRF-based post-retrieval process

3.7 전체 실험설계 및 평가수행 절차

본 연구에서는 군 도메인 환경에서의 LLM 성능을 정량적·정성적으로 평가하기 위해 RAG 적용 여부와 고급 RAG 기법의 효과를 단계적으로 검증하는 실험 워크플로우를 설계하였다. 전체 실험 절차는 Fig 3.에 제시되어 있으며, 그 흐름은 다음과 같다.

먼저, 군 도메인 적합도를 평가하기 위해 선정된 후보 LLM들을 대상으로 RAG를 적용하지 않은 환경(No-RAG)에서의 기본 성능을 평가하였다. 이 단계에서는 모델이 생성한 응답의 환각 발생 정도를 측정하

기 위하여, 정답 생성에 사용된 golden context와 RAGS 프레임워크의 Faithfulness 지표를 활용하였다. 또한 응답의 질의 적합성을 평가하기 위해 동일 프레임워크에서 제공하는 Answer Relevancy 지표를 사용하였다.

다음으로, Naive-RAG 기반 응답의 품질을 정량적으로 평가하기 위해서 RAGS 프레임워크에서 제공하는 Faithfulness, Answer Relevancy, Context Precision, Context Recall, 그리고 Precision과 Recall을 종합적으로 반영할 수 있는 F1-score를 활용하였다. 그리고 추가적인 자동 평가지표, 다시 말해 BLEU, ROUGE-1, ROUGE-2, ROUGE-L, BERTScore-F1을 활용하여 생성된 응답의 품질을 다각도로 평가하였다.

하지만 RAGS의 Answer Relevancy나 NLP기반 자동 평가지표들은 응답의 논리적 완결성이나 종합적인 품질을 충분히 반영하는 데에는 한계가 있다. 이에 GPT-4.1 모델을 활용하여 LLM-as-judge 기반 평가도 병행하였다. 이 평가에서는 생성된 답변을 정확성(Accuracy), 완전성(Completeness), 논리성 및 추론(Coherence & Reasoning), 표현력 및 정밀성(Expression & Precision)의 네 가지 기준에 따라 평가하였다. 아울러 정성적 평가(Qualitative Evaluation)를 위해 GPT가 생성한 평가 코멘트를 모델별로 요약·분석하였다.

이상의 평가 결과를 종합하여 군 도메인에 가장 적합한 최적의 로컬 LLM 모델을 선정하였다. 마지막으로, 선정된 모델을 대상으로 쿼리 최적화, 인덱싱 최적

화, 후처리 기법을 포함한 다양한 Advanced RAG 기법들을 단계적으로 적용하고, 각 조합에 따른 성능 변화를 비교·분석하여 최적의 Advanced RAG 시스템 구성 방안을 도출하였다. 본 연구에서 적용한 Advanced RAG 기법은 크게 쿼리 최적화(query optimization), 인덱싱 최적화(Index Optimization), 그리고 후처리(Post-retrieval processing)의 세 범주로 구성된다.

4. 실험 결과

4.1 No-RAG 베이스라인 실험 결과




Fig. 5. No-RAG experiment results

RAG를 적용하지 않았을 때, 모든 모델이 Answer Relevancy 지표를 기준으로 0.91에서 0.94 사이의 비교적 높은 점수를 기록하였다(Fig. 5). 이는 모델 규모와 무관하게 대부분의 모델이 질문의 전반적인 의도를 반영한 응답을 생성할 수 있음을 보여준다.

반면, Faithfulness 지표는 0.212에서 0.433 범위로 분포하여 전반적으로 낮은 수준을 나타냈다 (Fig. 5). 특히 GPT-20B와 GPT-120B 모델은 각각 0.245와 0.212로 가장 낮은 Faithfulness 점수를 기록하였다. Llama-8B 모델은 0.355로 GPT 계열 모델보다는 높은 충실도를 보였으나, Mistral-7B(0.376)와 QWEN-7B(0.395)에 비해서는 상대적으로 낮은 값을 보였다.

연구 결과, 모델 규모와 Faithfulness 간의 뚜렷한 상관관계는 관찰되지 않았다. 가장 큰 규모 모델인 Llama-405B는 0.433으로 본 실험에서 가장 높은 Faithfulness를 기록하였으나, Mistral-7B 및 Qwen-7B와 같은 소규모 모델과 비교했을 때 그 차이는 제한적인 수준에 그쳤다.

4.2 Naive-RAG 적용 실험 결과




Fig. 6. Naive-RAG experiment results

Fig. 6는 Naive-RAG를 적용한 실험 결과를 보여준다. No-RAG환경에서 GPT-120B와 Llama-405B는 각각 0.212와 0.433의 Faithfulness 점수를 기록하였으며, 외부 문맥을 활용하지 않는 실험 설정의 특성상 Context Precision, Context Recall, 그리고 F1 점수는 산출할 수 없었다. 반면, Naive-RAG를 적용한 모든 모델에서는 Faithfulness 점수가 0.591에서 0.706 범위로 크게 향상되었으며, Overall 성능 또한 0.752-0.772 수준으로 전반적인 성능 개선이 관찰되었다.

Context Precision은 모든 RAG 적용 모델에서 0.824-0.877 범위의 높은 성능을 보였다. 반면, Context Recall은 0.526-0.791 범위로 모델 간 편차가 비교적 크게 나타났다. 특히 GPT-20B는 Context Recall(0.791)과 F1 score(0.81)에서 가장 높은 점수를 기록하였다. 이에 비해 Mistral-7B(0.526), Qwen-7B(0.542), Llama-8B(0.541)는 상대적으로 낮은 Recall 성능을 보였다.

Faithfulness 측면에서는 Mistral-7B가 0.706으로 가장 높은 점수를 보였으며, Qwen-7B(0.685)와 Llama-8B(0.668)가 그 뒤를 이었다. GPT-20B는 0.591로 RAG 적용 모델 중 가장 낮은 Faithfulness를 기록하였다. 종합적으로, Naive-RAG 환경에서 Llama-8B(0.772)와 GPT-20B(0.765)가 가장 높은 Overall 성능을 기록하였다.




Fig. 7. No-RAG vs. Naive-RAG evaluation results based on LLM-as-judge




Fig. 8. Naive-RAG experiment results based on NLP metrics

Fig. 8은 NLP 기반 평가 지표를 활용하여 생성된 답변과 참조 답변간의 유사도를 분석한 결과를 보여준다. 실험 결과, RAG를 적용한 모든 모델은 No-RAG 환경에서 평가된 대규모 모델(GPT-120B, Llama-405B)에 비해 BLEU, ROUGE, BERTScore 전반에서 일관되게 더 높은 점수를 기록하였다. 특히, Overall 점수 기준으로 RAG 모델들은 0.365에서 0.395 범위를 보인 반면, No-RAG 모델들은 0.295에서 0.349 수준에 머물렀다.

모델별 비교에서는 Llama-8B 모델이 Overall 점수 0.395로 가장 높은 성능을 보였으며, 모든 ROUGE 계열 지표와 BERT F1에서도 가장 높은 값을 기록하였다. Mistral-7B와 Qwen-7B는 전반적으로 Llama-8B와 유사한 수준의 성능을 보였으나, GPT-20B는 상대

적으로 낮은 점수를 기록하였다.

한편 BLEU 점수는 모든 모델에서 0.044-0.151 범위로 전반적으로 낮은 절댓값을 보였다. 반면 ROUGE 및 BERT F1 점수는 상대적으로 높은 값을 기록하였으며, 특히 BERT F1은 모든 모델에서 0.847 이상으로 나타났다. 이는 의미적 유사성 측면에서는 모델 간 성능 차이가 비교적 제한적임을 보여준다.

4.3 No-RAG vs. Naive-RAG LLM-as-judge 실험결과

Fig. 7은 LLM-as-judge(GPT-4.1) 기반 평가를 통해 Accuracy, Completeness, Coherence & Reasoning, Expression & Precision 지표에서 모델별 성능을 비교한 결과를 보여준다. 실험 결과, 모든 모델 계열에서 RAG를 적용한 경우 네 가지 평가지표 전반에서 일관된 성능 향상이 관찰되었다.

FinalScore를 기준으로 살펴보면, RAG가 적용된 모델들은 7.47-8.96 범위를 기록한 반면, No-RAG 모델들은 6.35에서 8.30 범위에 머물렀다. 전체 모델 중에서는 GPT-20B RAG 모델이 FinalScore 8.96으로 가장 높은 평가를 받았으며, 특히 Accuracy(9.06)와 Completeness(8.95) 지표에서 우수한 성능을 보였다. 반면 No-RAG 환경에서는 Llama-405B가 FinalScore 8.30으로 가장 높은 점수를 기록하였다.

소규모 모델들에서도 RAG 적용에 따른 성능 개선이 뚜렷하게 나타났다. Qwen2-7B는 RAG 적용 후 FinalScore가 6.35에서 7.47로 향상되었으며,

Mistral-7B 역시 6.69에서 7.84로 큰 폭의 개선을 보였다. Llama-8B 또한 RAG 적용 시 FinalScore가 6.81에서 7.75로 증가하였다.

지표별로 살펴보면, Coherence & Reasoning 지표에서는 No-RAG 모델들도 비교적 높은 점수를 기록하였으나, Golden Answer 대비 사실 정확성과 정보 완전성을 평가하는 Accuracy와 Completeness 지표에서는 RAG 적용 시 더 큰 폭의 성능 향상이 관찰되었다. 종합적으로, RAG를 적용한 모든 모델에서 LLM-as-judge 기반 평가 점수가 일관되게 향상되었으며, 특히 정확도와 완전성 측면에서 가장 두드러진 개선 효과가 확인되었다.

질적 평가 결과 역시 앞서 제시한 정량적 평가 결과와 전반적으로 일관된 경향을 보였다. RAG를 적용하지 않은 대규모 모델인 GPT-120B와 Llama-405B의 경우, 전문적인 표현과 명확한 논리 전개 측면에서는 긍정적인 평가를 받았다. 그러나 세부 변수나 기술적 맥락의 누락이 반복적으로 관찰되었으며, 일부 개념의 과소 혹은 과대 강조, 그리고 Golden Answer에 없는 허위 정보(hallucination)의 포함과 같은 문제점이 지적되었다.

소규모 모델인 Mistral-7B, Qwen-7B, Llama-8B 역시 기본적인 개념 이해와 구조적인 답변 생성 측면에서는 일정 수준의 적합성을 보였으나, 세부 내용의 누락, 교리적·전술적 맥락의 부족, 정확하지 않은 용어 사용 등의 한계가 빈번히 나타났다. 이로 인해 전반적으로 Golden Answer 대비 깊이, 정밀성, 그리고 응답의 완결성 측면에서 상대적으로 낮은 평가를 받았다.

반면, RAG를 적용한 경우 모든 모델에서 Golden Answer와의 적합성이 뚜렷하게 향상되었다. 특히 교리 교범에 기반한 세부 정보, 전술적 요소, 기술적 맥락이 보다 정확하게 반영되었으며, 논리 전개와 응답 구조 측면에서도 전반적인 개선이 관찰되었다. 특히 GPT-20B 모델은 RAG 적용 시 정확성, 완결성, 전문성 측면에서 Golden Answer와 거의 동일하거나 일부 경우에는 이를 상회하는 수준의 답변을 생성한 것으로 평가되었다.




Fig. 9. Advanced RAG index optimization experiment results

4.4 GPT-20B Advanced RAG 적용 실험결과

Fig 9는 고급 RAG기법 중 서로 다른 네 가지 인덱스 최적화 방법을 적용한 실험 결과를 보여준다. 평가 결과, Summary 인덱스와 Parent-Child 인덱스가 각각 0.796과 0.793의 Overall 성능을 기록하며 가장 우수한 성능을 보였다. 이는 기본 Default RAG(0.7647) 대비 각각 0.0316, 0.0283의 성능 향상에 해당한다. 반면, Hypothetical Question 인덱스는 0.7603으로 Default RAG와 유사한 성능 수준을 유지했으며, Granular Chunk Expansion 인덱스는 0.7187로 모든 기법 중 가장 낮은 Overall 성능을 기록하였다.

검색 정확도와 포괄성을 나타내는 Context Precision과 Context Recall 측면에서는 Parent-Child 인덱스가 각각 0.907과 0.813으로 가장 높은 점수를 보였다. 또한 이 두 지표의 균형을 반영하는 F1 점수에서도 Parent-Child 인덱스는 0.86을 기록하며, 검색 품질의 안정성과 균형 측면에서 가장 우수한 성능을 나타냈다.

충실도(Faithfulness) 지표에서는 Summary 인덱스(0.651)와 Parent-Child 인덱스(0.642)가 상대적으로 높은 성능을 보였다. 반면, Granular Chunk Expansion 인덱스는 0.519로 Naive-RAG(0.591)보다 낮은 성능 점수를 기록하였다. 응답 적합도(Answer Relevancy) 측면에서는 Summary 인덱스가 0.91로 가장 높은 관련성을 보였다. 이러한 결과를 바탕으로, 후속 실험에서는 전반적인 평가지표에서 가장 안정적인 성능을 보인 기법 중 하나인 Parent-Child 인덱스를 대상으로 쿼리 최적화 및 RRF기반 후처리 기법을 추가로 적용하여, 각 조합별 성능을 비교 분석하였다.

Fig. 10에 따르면, 기본 Parent-Child 인덱스(0.793)와 비교했을 때, 쿼리 확장 기법을 적용한 모델은




Fig. 10. Advanced RAG, query optimization and RRF post-processing experiment results

Overall 성능 0.841을 기록하며 가장 큰 성능 향상을 보였다. 이는 본 실험에서 관찰된 결과 중 최고 성능에 해당한다. 쿼리 확장 및 RRF 기반 후처리 기법을 동시에 적용한 경우에도 Overall 성능은 0.825로 나타나, 전체 실험 설정 중 두 번째로 높은 성능을 기록하였다.

세부 지표별로 살펴보면, Context Precision은 기본 Parent-Child 인덱싱이 0.907로 가장 높은 점수를 유지하였다. 반면, Context Recall은 쿼리 확장과 후처리를 동시에 적용했을 때 각각 0.871과 0.879로 큰 폭 향상되는 결과를 보였다. Faithfulness 측면에서는 쿼리 확장 기법을 적용한 모델이 0.75로 가장 높은 점수를 기록하였다. F1 점수의 경우 쿼리 확장과 후처리 기법을 같이 적용했을 때 0.88로 가장 높게 나타났으며, 이는 다중 쿼리 생성과 RRF 조합이 검색 정확도와 포괄성 간의 균형을 가장 효과적으로 달성했음을 보여준다.

4.5 Bootstrapping을 통한 통계적 유의성 검증

마지막으로 본 연구에서 제안한 모델 및 각 기법별 성능 향상의 통계적 유의성을 검증하기 위해, Overall 성능 지표를 이용하여 부트스트랩(Bootstrap, N=1,000) 기반의 95% 신뢰구간(Confidence Interval, CI) 분석을 수행하였다. Fig. 11과 Table 3에 나타난 바와 같이, 기본 모델인 GPT-20B-RAG(Mean: 0.775, 95% CI [0.732, 0.810])는 대조군인 Llama-405B(Mean: 0.680, 95% CI [0.647, 0.711])와 신뢰 구간이 전혀 중첩되지 않는 뚜렷한 성능 우위를 나타냈다. 또한, 인덱싱 최적화의 핵심인

Parent-Child(Mean: 0.810, 95% CI [0.771, 0.843])와 Summary 인덱싱(Mean: 0.808, 95% CI [0.771, 0.842]) 기법 역시 타 설정 대비 상대적으로 우수한 성능 분포를 보여주었다. Query Expansion(Mean: 0.846, 95% CI [0.802, 0.881])과 Query Expansion+RRF(Mean: 0.837, 95% CI [0.808, 0.864]) 기법은 가장 높은 평균 성능을 기록하였으나, 다른 Advanced RAG 기법들과 신뢰구간 중첩이 관찰되므로 기법 간의 우열을 일반화하기에는 신중함이 요구된다.

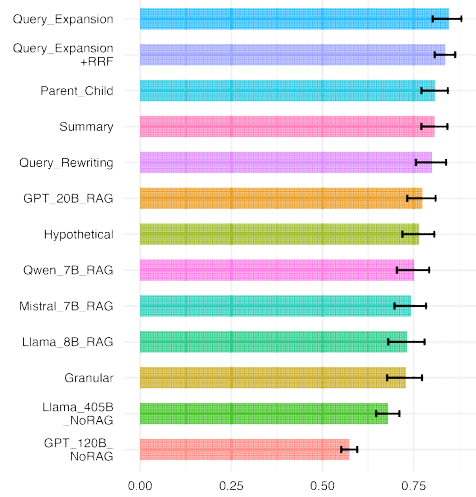


Fig. 11. Overall scores with 95% bootstrap confidence intervals for various RAG configurations and LLM baselines (N=1,000 resamples)

Table 3. Overall scores for various RAG configurations and LLM baseline with 95% bootstrap confidence interval

Model	Mean	LowerCI	UpperCI
Llama-405B-NoRAG	0.680	0.647	0.711
GPT-120B-NoRAG	0.574	0.551	0.595
Llama-8B-RAG	0.733	0.680	0.780
Mistral-7B-RAG	0.743	0.697	0.784
Qwen-7B-RAG	0.751	0.704	0.792
GPT-20B-RAG	0.775	0.732	0.810
Granular	0.729	0.677	0.773
Hypothetical	0.765	0.719	0.806
Parent-Child	0.810	0.771	0.843
Summary	0.808	0.771	0.842
Query-Rewriting	0.801	0.756	0.839
Query-Expansion	0.846	0.802	0.881
Query-Expansion+RRF	0.837	0.808	0.864

5. 토론

5.1 No-RAG 실험 결과 논의

No-RAG 환경에서 실험에 사용된 모든 모델은 Answer Relevancy와 BERT F1 지표에서 전반적으로 높은 점수를 기록하였다. 또한 LLM-as-judge 기반 질적 평가 결과, GPT-120B와 Llama-405B 모델은 타 모델 대비 상대적으로 우수한 논리적 일관성과 추론 능력(Coherence & Reasoning)을 보였다. 이는 대규모 언어모델이 외부 문맥 정보 없이도 언어적 유창함과 일반적 추론 능력을 바탕으로 사용자 질문의 의도를 반영한 응답을 생성할 수 있음을 시사한다.

반면 생성된 답변이 실제 근거에 얼마나 충실한지를 평가하는 Faithfulness 지표에서는 No-RAG 모델들이 RAG를 적용한 모델들과 비교하여 전반적으로 낮은 성능을 보였다. 또한 질적 평가에서도 Accuracy와 Completeness 측면에서 GPT-120B와 Llama-405B 모두 Naive-RAG를 적용한 GPT-20B 대비 낮은 점수를 기록하였다. 이러한 결과는 RAG를 적용하지 않은 모델들이 표면적으로는 타당해 보이는 응답을 생성할 수 있으나, 실제로는 명시적 근거에 기반한 신뢰성 있는 답변을 생성하는 데에는 한계가 있음을 의미한다. 다시 말해, No-RAG 환경에서는 모델의 규모와 상관없이 환각 문제에 여전히 취약할 수 있으며, 사실 정확성과 근거 충실도가 특히 중요한 군 도메인 환경에서는 RAG 또는 미세조정(finetuning) 기반 접근 방식이 필수적임을 시사한다.

No-RAG 환경에서 관찰된 또 하나의 결과는 소규모 모델(Qwen-7B, Mistral-7B, Llama-8B)이 중간 규모 모델인 GPT-20B보다 높은 Faithfulness 점수를 기록했다는 점이다. 이러한 현상의 원인을 명확히 규명하기는 어려우나, 모델별 사전학습 데이터 코퍼스의 구성 차이가 도메인 적합성에 영향을 미쳤을 가능성을 배제할 수 없다. 비공개 모델의 경우 구체적인 학습 데이터 분포를 확인하는 데 한계가 있으나, 특정 모델이 특정 도메인에서 일관된 성능 우위를 보인다는 사실은 도메인 특화 LLM 시스템을 설계할 때 사전 학습 데이터의 구성이 성능에 영향을 미치는 핵심 요인으로 작용할 수 있음을 시사한다.

한편, 본 실험에서 사용된 가장 큰 규모의 모델인 Llama-405B는 군 교리 관련 지식에 대한 학습 커버

리지가 상대적으로 넓었을 것으로 추정된다. 이로 인해 외부 문맥의 보조 없이도 과도한 추론에 의지하지 않고 이미 학습된 지식을 바탕으로 비교적 정확한 응답을 생성할 수 있었던 것으로 해석된다.

5.2 Naive-RAG 실험결과 논의

Naive-RAG를 적용한 결과, 실험에 사용된 모든 모델에서 전반적인 성능 향상이 뚜렷하게 관찰되었다. 특히 RAG를 적용한 소규모 모델들은 Faithfulness, BLEU, ROUGE 지표에서 GPT-120B 및 Llama-405B와 같은 대규모 모델을 상회하는 성능을 보여주었다. 또한 LLM-as-judge 평가 결과, Naive-RAG 적용 시 Accuracy와 Completeness 측면에서 가장 명확한 성능 개선이 나타났다.

또한 질적 평가 결과를 통해, RAG는 단순한 정보 보강을 넘어 기존의 암묵적 추론에 의존하던 응답을 명시적인 근거에 기반한 형태로 전환하는 데 기여할 수 있음을 확인하였다. 구체적으로, 교리 교범 용어의 정확한 사용, 기술적 세부 묘사, 통계 수치 참조 등과 같이 높은 정확성이 요구되는 영역에서 RAG의 효과가 가장 두드러지게 나타났다. 이러한 결과는 RAG 기법이 환각 문제를 실질적으로 완화하며, 모델 규모 차이에서 기인하는 성능의 한계를 보완할 수 있는 효과적인 접근 방식임을 시사한다.

그러나 소규모 모델들은 RAG 적용 이후에도 불필요한 정보의 삽입이나 사실적 근거가 부족한 응답을 생성하는 등의 문제가 여전히 빈번하게 관찰되었다. 또한 모든 소규모 모델은 Context Precision에서는 상대적으로 높은 점수를 보인 반면, Context Recall에서는 낮은 성능을 나타냈는데, 이는 이들 모델들이 대규모 모델들에 비해 보수적인 검색 전략을 취하고 있음을 의미한다.

한편, GPT-20B 모델은, 높은 Context Recall과 상대적으로 낮은 Faithfulness 점수를 동시에 보였으며, 이는 보다 광범위한 문맥을 활용하는 추론 과정에서 불필요한 정보가 최종 답변에 함께 포함되었을 가능성을 시사한다. 종합적으로 볼 때, Naive-RAG 기법만으로는 소규모 모델의 구조적 한계를 완전히 극복하기에는 부족하며, 이러한 한계는 Advanced RAG 기법 적용의 필요성을 뒷받침하는 실험적 근거로 해석될 수 있다.

5.3 Advanced RAG 인덱스 최적화 실험결과 논의

Advanced RAG 기법 중 인덱스 최적화(index optimization) 전략에 대한 실험 결과, Summary 기반 인덱스와 Parent-Child 기반 인덱스 기법이 전반적으로 가장 우수한 성능을 보였다. 특히 Summary 인덱스는 모든 평가지표에서 안정적인 성능을 보였으며, Overall 성능 기준으로 가장 높은 점수를 보였다. 이는 문서의 핵심 의미를 요약한 정보를 메타데이터로 활용하여, 사용자 쿼리와 문서 간의 의미적 대응 관계를 더 명확하게 형성할 수 있었기 때문으로 해석된다. 그리고 요약된 핵심 정보를 기반으로 검색이 수행됨에 따라, 불필요한 세부 정보가 컨텍스트에 포함되는 현상을 줄이고, 모델의 과도한 추론이나 응답 불안정성을 감소시켜 전반적인 응답 품질 향상에 기여한 것으로 판단된다.

Parent-Child 인덱스 기법은 Context Precision과 Context Recall 지표에서 가장 높은 성능을 기록하였다. 이는 본 기법이 검색 단계에서 불필요한 문서의 포함을 효과적으로 줄이면서도, 질문에 필요한 문맥을 안정적으로 제공하는 데 유효한 접근 방식임을 의미한다. 특히, 본 기법은 세부 청크 단위에서 1차 검색을 수행한 후, 관련 상위 문맥(parent context)을 제공하는 검색 특성으로 인하여, 문맥 단절(context fragmentation) 문제를 완화하고 모델이 더 풍부한 컨텍스트를 고려하여 답변을 생성하도록 하는데 긍정적인 영향을 미친 것으로 해석된다.

반면, 가상 질문 임베딩 기법은 Naive-RAG 대비 다소 낮은 지표를 기록하였다. 이는 본 실험 환경에서 생성된 가상 질문이 사용자 질의의 구체적 의도를 충분히 포괄하지 못하여 검색 정밀도에 부정적인 영향을 미쳤을 가능성을 시사한다. 예를 들어, 북한군의 제대 편성 관련 질의에 대해, 타 기법은 “제1제대에 약 2/3(67%)배치”와 같은 정량적 수치를 제공하며 정보 밀도 측면에서 상대적인 우위를 보인 반면, 가상 질문 기반 검색은 “계층적 제대”와 같은 일반적 검색에 머무는 한계를 보였다. Granular Chunk Expansion 기법 또한 낮은 성능을 기록하였는데, 이는 과도한 문서 세분화에 따른 맥락의 파편화가 모델의 불완전한 근거 참조 및 응답 생성으로 이어지기 쉽기 때문으로 풀이된다. 구체적으로, “적 C2파괴” 관련 질의에서 Granular 방식은 “소규모 기동팀의 물

리적 타격”이라는 제한된 정보를 제시하는데 국한되었으나, Summary 파이프라인은 “센서-슈터 결합(Sensor-to-Shooter links) 저하” 및 “타겟팅 데이터 조작을 통한 자원 낭비 유도” 등 체계적 효과까지 포함한 좀 더 구체적인 정보를 제공하였다.

이러한 인덱스 최적화 결과를 종합할 때, Parent-Child 또는 Summary 기반 인덱싱은 군사 도메인과 같이 문맥의 연속성과 사실 정확성이 중시되는 환경에서 LLM 기반 시스템을 구축하기 위한 실용적인 대안으로 판단된다. 다만, 69개의 샘플 데이터셋만으로 특정 기법의 우위를 일반화하기에는 통계적 한계가 존재함으로 해석에 유의할 필요가 있다.

5.4 Advanced RAG 쿼리 최적화 후처리 실험결과 논의

실험 결과, 쿼리확장 기법의 적용은 단일 쿼리로는 포착하기 어려운 다양한 의미 표현과 관점을 검색 단계에서 반영하도록 하여, Context Recall을 유의미하게 향상시키는 효과를 보였다. 특히 쿼리 확장이 Parent-Child 인덱스와 결합된 경우, 근거 단절을 최소화 하고 더 풍부한 컨텍스트를 제공하는 효과가 있음을 연구 결과를 통하여 확인하였다. 또한 쿼리 확장의 적용이 높은 충실도 점수와 이어진 점은, 본 기법이 단순히 검색 범위를 확장하는데 그치지 않고, LLM이 보다 명시적인 근거에 기반한 응답을 생성하도록 유도함으로써 응답 품질 전반의 개선으로 연결될 수 있음을 의미한다.

반면 쿼리 재작성의 경우 응답 적합성 측면에서는 개선된 결과를 보여주었으나, 충실도와 전반적인 모델 성능에 미치는 영향은 제한적인 것으로 나타났다. 이는 재작성 과정에서 질의의 핵심 키워드나 의미적 초점이 일부 희석되었거나, 검색 대상 문서의 범위가 오히려 축소되었을 가능성을 시사한다.

후처리 기법인 Reciprocal Rank Fusion의 경우, 다중 쿼리로부터 도출된 검색 결과를 안정적으로 통합하여 Context Recall과 F1 점수를 향상시키는 효과를 보였지만, Faithfulness와 전반적인 성능 지표에서는 소폭의 성능 저하가 관찰되었다. 이는 RRF가 서로 다른 쿼리 결과를 병합하는 과정에서 일부 부차적이거나 핵심 내용과 거리가 있는 컨텍스트를 함께 포함하였을 가능성을 시사한다. 그럼에도 불구하고 RRF는 검색된 청크 간의 중복을 효과적으로 줄이면서도

다른 기법들에 비하여 비교적 풍부한 문맥을 제공할 수 있다는 장점을 갖는다. 이러한 특성은 전반적인 LLM 시스템 운용 측면에서 입력 토큰 수 감소와 추론 지연 시간(latency) 단축으로 이어질 수 있기 때문에 실제 운용 환경 구축에 있어서 충분히 고려할 수 있는 효과적인 대안이다.

6. 결론

본 연구의 목적은 보안 및 운용 제약이 엄격한 폐쇄망 환경에서 군사 전문 도메인 지식에 특화된 고성능 질의응답 시스템을 구축하고, 이를 구현하기 위한 실질적이고 구체적인 기술적 방법론을 제시하는데 있었다.

이를 위해 본 연구에서는 온프레미스 환경에서 LLM 애플리케이션의 안정적인 운용을 고려하여 NVIDIA A6000 GPU를 기반으로 소규모 언어모델부터 20B 수준의 중간 규모 모델까지 구동 가능한 시스템 환경을 구축하였다. 또한 고성능 GPU 자원의 최적화된 성능을 보장하기 위해 vLLM 추론엔진을 사용하였다. 최적의 SLLM 선정에 대해서는 Qwen-7B, Mistral-7B, Llama-8B, GPT-OSS-20B를 실험군 모델로 선정하였고, 대규모 모델과의 벤치마킹을 위해 GPT-OSS-120B와 Llama-405B를 비교군 모델로 사용하였다.

실험 설계 측면에서는 RAG를 적용하지 않은 No-RAG 환경과 Naive-RAG 환경의 성능을 우선 비교한 뒤, 선정된 최적 모델을 대상으로 쿼리 최적화, 인덱스 최적화, 후처리 기법으로 구성된 Advanced RAG 기법을 단계적으로 적용하여 추가적인 성능 향상을 분석하였다. 모델 평가는 응답 적합도, 문맥 적합도, 충실도를 중심으로 한 RAGS 프레임워크를 기반으로 수행하였으며, 여기에 NLP 기반 자동 평가 지표와 LLM-as-judge 평가를 병행하여 좀 더 다차원적이고 포괄적인 LLM 평가 방안을 제시하고자 하였다.

실험 결과, RAG를 적용하지 않은 환경에서는 GPT-OSS-120B와 Llama-405B와 같은 대규모 모델들이 응답 적합도와 논리적 일관성 및 추론 능력 측면에서 상대적으로 우수한 성능을 보였다. 그러나 충실도 측면에서는 RAG를 적용한 소규모 모델들에 비해 현저히 낮은 성능을 기록하였다. 이는 대규모 언어 모델이 외부 근거 없이도 표면적으로 타당해 보이는

답변을 생성할 수는 있으나, 명시적인 근거에 기반한 신뢰성 있는 답변을 생성하는 데에는 본질적인 한계가 있음을 시사한다. 반면, Naive-RAG를 적용한 경우 모든 모델에서 충실도가 유의미하게 향상되었으며, 특히 소규모 모델들이 대규모 모델을 상회하는 결과를 보였다는 점은 RAG 기법이 LLM의 암묵적 추론 중심 응답을 명시적 근거 기반 응답으로 전환하는 데 실질적인 효과가 있음을 보여준다. 종합적으로 평가한 결과, GPT-OSS-20B 모델은 RAG 적용 시 가장 안정적인 성능을 나타냈으며, 특히 정확성, 완결성, 전문성 및 추론 능력 전반에서 가장 우수한 성능 향상을 보였다. 군 도메인에서는 모델의 정확성뿐만 아니라 효과적인 의사결정 지원을 위한 추론 능력 또한 중요하므로, 본 연구 결과는 시스템 자원이 허용되는 환경에서는 상대적으로 큰 규모의 모델을 활용하는 것이 보다 효과적일 수 있음을 시사한다.

나아가 Advanced RAG 실험 결과, Summary 인덱스와 Parent-Child 인덱스 기법이 전반적인 성능 측면에서 가장 우수한 성능을 보였다. 또한 이러한 고급 인덱싱 기법에 쿼리 확장 기법을 결합하거나 RRF 기반 후처리 기법을 적용할 경우, 검색 품질 및 응답 품질이 추가적으로 개선될 수 있음을 확인하였다.

이러한 실험 결과를 종합할 때, 본 연구의 주요 기여는 다음과 같이 정리할 수 있다. 본 연구는 보안 요구와 자원 제약이 공존하는 온프레미스 폐쇄망 환경을 전제로, 경량 SLLM과 Advanced RAG 기법을 결합한 시스템 아키텍처를 설계하고 실증 실험을 통해 각 기술 조합의 효과를 분석하였다. 비록 특정 군사 교범과 한정된 평가 데이터셋을 활용했다는 실험적 한계가 있으나, 실제 군 도메인 데이터를 적용하여 폐쇄망 내 지식 질의응답 시스템 구현을 위한 기술적 접근 방안을 구체적으로 탐색하였다는 점에서 기초적인 의미가 있다. 본 연구 결과는 향후 실체계 적용 가능한 온프레미스 기반 LLM 시스템 개발시 실무적인 참고 가이드라인을 제공할 수 있을 것으로 기대된다.

또한 본 연구는 실제 미군 교리/교범 데이터셋을 기반으로 여러 소규모 및 중간 규모 모델에 정량적 벤치마킹을 수행하고, 이를 대규모 모델과 비교 분석함으로써, 도메인 특화 질의응답 시스템 구축 시 모델 선정 기준과 활용 가능성에 대한 구체적인 근거를

제시하였다. 이는 국방 분야에서 LLM 기반 시스템 도입을 위한 실무적 가이드라인을 제공한다는 점에서 의미를 갖는다.

더 나아가 본 연구는 복잡하고 계층적인 군 교리·교범 데이터의 특성을 분석하고, 이에 최적화된 Advanced RAG 파이프라인을 설계 및 구현하였다. 본 연구의 핵심은 기존 기법의 단순한 적용을 넘어, 군사 도메인의 특수성을 반영한 전략적 기법 조합을 도출하는 데 있다. 구체적으로는 방대한 교범 내 문맥 유실을 방지하고 풍부한 문맥 유지를 위한 Parent-Child인덱싱 전략, 사용자 질의의 모호성을 해결하기 위한 쿼리 최적화, 그리고 검색 결과의 노이즈를 제거하여 답변의 정밀도를 높이는 후처리 기법의 유기적 결합 방안을 제시하였다. 이를 통해, 군사 폐쇄망이라는 제한된 환경에서 실효성이 높은 최적의 기술 스택을 실증적으로 규명함으로써, 실제 군사 폐쇄망 적용시 고려해야 할 구현상의 제약 조건과 이에 따른 실무적 가이드라인을 제공한다.

한편, 본 연구는 다음과 같은 한계점을 지닌다. 우선 통계적 유의성 및 일반화와 관련된 한계이다. 본 연구에 사용된 데이터셋은 69개의 소규모 샘플이며, LLM을 활용한 합성데이터(Synthetic data)를 기반으로 구축되었다. 이는 실제 도메인의 복잡한 교리·교범 체계 전체를 대표하기에는 부족하며, 특히 합성 데이터 기반의 평가는 실제 사용자의 다변화된 질의 패턴을 온전히 반영하지 못할 가능성이 있다. 이로 인해 본 실험 결과를 군사 도메인 전반으로 일반화하여 결론을 도출하기에는 통계적 한계가 존재한다. 따라서 향후 연구에서는 본 연구의 방법론을 토대로, 도메인 전문가가 직접 검증하고 구축한 수백에서 수천 건 규모의 대규모 평가 데이터셋을 구축하여 실험 결과의 통계적 유의성과 모델의 일반화 능력을 검증할 필요가 있다.

또한, 본 연구의 성능평가 단계에서 평가지표의 객관성 확보를 위해 상용 LLM인 OpenAI의 GPT-4.1 모델을 판정자로 활용하였으나, 이는 본 연구가 지향하는 ‘완전한 온프레미스 폐쇄망 환경’과 실제 운용·보안 환경 간 괴리를 야기한다는 점에서 한계를 지닌다. 이를 해결하기 위한 실무적 대안으로, Llama-3-70B 또는 Qwen-2.5-72B와 같이 추론 능력이 검증된 대규모 오픈소스 모델을 폐쇄망 내부에 구축하여 평가 모

델로 운영하는 방안을 고려할 수 있다. 이에 더해, 자동화된 평가의 편향성을 최소화하고, AI의 생성물을 다시 AI가 평가할 때 발생할 수 있는 ‘에코 챔버(Echo Chamber)’ 효과를 억제하기 위해 군사 전문가의 교차 검증(Human-in-loop)을 병행하는 평가 체계가 필요하다. 이러한 다각적인 접근은 생성부터 평가에 이르는 전 과정을 오프라인화한 엔드투엔드(End-to-End) 폐쇄망 시스템 구현을 가능하게 할 것이며, 이는 실제 체계 적용 시 보안성과 신뢰성을 동시에 담보할 수 있는 핵심 대책으로서 향후 연구를 통해 심도 있게 다루어져야 할 과제이다.

이와 더불어, 본 연구는 시스템 성능 최적화를 위한 기술적 방법론의 범위를 SFT(Supervised Fine-Tuning)나 LoRA 등 별도의 미세조정을 거치지 않은 상태에서의 RAG 아키텍처 효과 분석으로 한정하였다는 한계가 있다. 관련 문헌 연구에 따르면, 도메인 특화 LLM 개발 시 RAG 단독 적용보다 미세조정을 병행했을 때 더 큰 성능 향상을 보인 사례가 다수 보고되고 있다. 따라서 본 연구에서 도출된 “RAG를 통한 성능 향상” 결과는 전문 도메인에 최적화된 미세조정 모델과의 직접적인 비교 결과가 아님에 유의해야 한다. 본 연구는 자원 제약 폐쇄망 환경에서의 효율적인 RAG 전략 수립에 초점을 맞추었으며, 미세조정 기법과의 결합을 통한 추가적인 성능 최적화 및 두 방법론 간의 정밀한 비교 분석은 향후 과제로 남긴다.

또한 최근에는 Modular RAG, Adaptive RAG, 지식 그래프(Knowledge Graph) 연계, 외부 데이터베이스 연동, 쿼리 라우팅(query routing) 등과 같이 RAG 구조를 고도화하기 위한 다양한 기법들이 빠르게 발전하고 있으나, 본 연구에서는 이러한 확장된 RAG 기법들을 포괄적으로 분석하지 못했다는 점 역시 한계로 남는다.

따라서 향후 연구에서는 추가적인 RAG 시스템 고도화 전략과 미세조정 기법을 함께 적용했을 때의 효과를 체계적으로 분석하고, 군 도메인 환경에서의 실질적인 운용 가능성과 확장성을 검증할 필요가 있다. 이를 통해 군사적 의사 결정 지원과 같이 정확성과 신뢰성이 요구되는 환경에서 온프레미스 LLM 시스템의 안정성 확보와 전반적인 성능 향상에 기여할 수 있을 것으로 기대된다.

References

- [1] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, et al., "Attention Is All You Need", *Advances in Neural Information Processing Systems 30 (NIPS 2017)*, Curran Associates. Inc., Long Beach. CA. USA, Vol. 30, pp. 5998-6008, Jun. 2017.
- [2] M. Shoenybi, M. Patwary, R. Puri, P. LeGresley, J. Casper, et al., "Megatron-LM: Training Multi-Billion Parameter Language Models Using Model Parallelism", arXiv preprint arXiv:1909.08053, Sep. 2019.
DOI: <https://doi.org/10.48550/arXiv.1909.08053>
- [3] J. Wei, Y. Tay, R. Bommasani, C. Raffel, B. Zoph, et al., "Emergent Abilities of Large Language Models", *Transactions on Machine Learning Research*, Jun. 2022.
- [4] Z. Z. Chen, J. Ma, X. Zhang, N. Hao, A. Yan, et al., "A Survey on Large Language Models for Critical Societal Domains: Finance, Healthcare, and Law", *Transactions on Machine Learning Research*, May. 2024.
- [5] Z. Zhou, L. Ma, H. Liu, "Trade the Event: Corporate Events Detection for News-Based Event-Driven Trading", *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*, Association for Computational Linguistics, Online, pp.2114-2124, Aug. 2021.
DOI: <https://doi.org/10.18653/v1/2021.findings-acl.186>
- [6] Y. Soun, J. Yoo, M. Cho, J. Jeon, U. Kang, "Accurate Stock Movement Prediction with Self-supervised Learning from Sparse Noisy Tweets", *Journal of Institute of Electrical and Electronics Engineers*, Dec. 2022.
DOI: <https://doi.org/10.1109/BigData55660.2022.10020720>
- [7] C. Wu, W. Lin, X. Zhang, Y. Zhang, W. Xie, et al., "PMC-LLaMA: toward building open-source language models for medicine", *Journal of the American Medical Informatics Association*, Vol.31, No.9, pp.1833-1843, Apr. 2024.
DOI: <https://doi.org/10.1093/jamia/ocae045>
- [8] Q. Xie, Q. Chen, A. Chen, C. Peng, Y. Hu, et al., "Me LLaMA: Foundation Large Language Models for Medical Applications", arXiv preprint arXiv:2402.12749, Feb. 2024.
DOI: <https://doi.org/10.21203/rs.3.rs-4240043/v1>
- [9] S. Wu, O. Irsoy, S. Lu, V. Dabrovolski, M. Dredze, et al., "BloombergGPT: A Large Language Model for Finance", arXiv preprint arXiv:2303.17564, Mar. 2023.
DOI: <https://doi.org/10.48550/arXiv.2303.17564>
- [10] C. Wu, J. Lei, Q. Zheng, W. Zhao, W. Lin, et al., "Can GPT-4V(ision) Serve Medical Applications? Case Studies on GPT-4V for Multimodal Medical Diagnosis", arXiv preprint, Oct. 2023.
DOI: <https://doi.org/10.48550/arXiv.2310.09909>
- [11] Z. Yang, L. Li, K. Lin, J. Wang, C. Lin, et al., "The Dawn of LMMs: Preliminary Explorations with GPT-4V(ision)", arXiv preprint arXiv:2309.17421, Sep. 2023.
DOI: <https://doi.org/10.48550/arXiv.2309.17421>
- [12] H. Touvron, T. Lavril, G. Izacard, X. Martinet, M. Lachaux, et al., "LLaMA: Open and Efficient Foundation Language Models", arXiv preprint arXiv:2302.13971, Feb. 2023.
DOI: <https://doi.org/10.48550/arXiv.2302.13971>
- [13] S. Yuk, Y. Cho, "Recent Trends on Generative AI in National Defense", *Journal of Internet Computing and Services*, Vol.26, No.1, pp.203-209, Feb. 2025.
DOI: <https://doi.org/10.7472/jksii.2025.26.1.203>
- [14] K. Moon, M. Kang, H. Y. Yu, Y. Shin, "Research on the Application of Large Language Models (LLMs) in the Defense Domain", *Journal of The Korea Academia-Industrial cooperation Society*, Vol.25, No. 8, pp.484-492, Aug. 2024.
DOI: <https://doi.org/10.5762/KAIS.2024.25.8.484>
- [15] W. N. Caballero, P. R. Jenkins, "On Large Language Models in National Security Applications", arXiv preprint arXiv:2407.03453, Jul. 2024.
DOI: <https://doi.org/10.48550/arXiv.2407.03453>
- [16] C. A. Chochtoulas, "How Large Language Models are Transforming Modern Warfare", *Journal of Joint Air Power Competence Centre*, May. 2024.
- [17] W. Cho, J. Yoo, S. M. Kim, J. Jang, "RAG-Enhanced small Large Language Models: Enhancing Battlefield Analysis through Knowledge Distillation of Large Language Models", *Journal of The Korea Society of Computer and Information*, Mar. 2025.
DOI: <https://doi.org/10.9708/jksii.2025.30.03.043>
- [18] J. Puigcerver, C. Riquelme, B. Mustafa, N. Houlsby, "From Sparse to Soft Mixtures of Experts", *Proceedings of the 12th International Conference on Learning Representations (ICLR 2024)*, International Conference on Learning Representations, Vienna Austria, May. 2024.
- [19] A. Gudibande, E. Wallace, C. Snell, X. Geng, H. Li, et al., "The False Promise of Imitating Proprietary LLMs", arXiv preprint arXiv:2305.15717, May. 2023.
DOI: <https://doi.org/10.48550/arXiv.2305.15717>
- [20] Z. Wan, X. Wang, C. Liu, S. Alam, Y. Zheng, et al., "Efficient Large Language Models: A Survey", *Journal of Transactions on Machine Learning Research*, Dec. 2023.
- [21] N. Muennighoff, L. Soldaini, D. Groeneveld, K. Lo, J. Morrison, et al., "OLMoE: Open Mixture-of-Experts Language Models", *Proceedings of the 13th International Conference on Learning Representations (ICLR 2025)*, International Conference on Learning Representations, Singapore, Apr. 2025.
- [22] Roberto Infante, AI Agents and Applications With LangChain, LangGraph, and MCP(v7), p.476, Manning Publications, 2025, pp.317-354
- [23] J. Manchanda, L. Boettcher, M. Westphalen, J. Jasser, "The Open Source Advantage in Large Language Models (LLMs)", arXiv preprint arXiv:2412.12004, Dec. 2024.
DOI: <https://doi.org/10.48550/arXiv.2412.12004>
- [24] J. A. H. Ivarro, J. G. Barreda, "An advanced retrieval-augmented generation system for manufacturing quality control", *Journal of Advanced Engineering Informatics*, Vol.64, No.103007, Mar. 2025.
DOI: <https://doi.org/10.1016/j.aei.2024.103007>

- [25] Y. Zhang, Y. Li, L. Cui, D. Cai, L. Liu, et al., "Siren's Song in the AI Ocean: A Survey on Hallucination in Large Language Models", *Journal of Computational Linguistics*, Vol.51, No.1, pp.1-55, Sep. 2023.
DOI: <https://doi.org/10.1162/COLLA.16>
- [26] N. Kandpal, H. Deng, A. Roberts, E. Wallace, C. Raffel, "Large Language Models Struggle to Learn Long-Tail Knowledge", *Proceedings of the 40th International Conference on Machine Learning (ICML 2023)*, PMLR, Honolulu, Hawaii, USA, No.641, pp.1569-615707, Jul. 2023.
- [27] M. Dahl, V. Magesh, M. Suzgun, D. E. Ho, "Large Legal Fictions: Profiling Legal Hallucinations in Large Language Models", *Journal of Legal Analysis*, Vol.16, No.1, pp.64-93, Jun. 2024.
DOI: <https://doi.org/10.1093/jla/laec003>
- [28] S. Salehi, Y. Singh, K. K. Horst, Q. A. Hathaway, B. J. Erickson, "Agentic AI and Large Language Models in Radiology: Opportunities and Hallucination Challenges", *Bioengineering*. MDPI, Vol.12, No.12, pp.1303, Nov. 2025.
DOI: <https://doi.org/10.3390/bioengineering12121303>
- [29] Y. Gao, Y. Xiong, X. Gao, K. Jia, J. Pan, et al., "Retrieval-Augmented Generation for Large Language Models: A Survey", arXiv preprint arXiv.2312.10997, Dec. 2023.
DOI: <https://doi.org/10.48550/arXiv.2312.10997>
- [30] A. Bora, H. Cuayhuil, "Systematic Analysis of Retrieval-Augmented Generation-Based LLMs for Medical Chatbot Applications", *Machine Learning and Knowledge Extraction*, Vol.6, No.4, pp.2355-2374, Oct. 2024.
DOI: <https://doi.org/10.3390/make6040116>
- [31] W. Fan, Y. Ding, L. Ning, S. Wang, H. Li, et al., "A Survey on RAG Meeting LLMs: Towards Retrieval-Augmented Large Language Models", *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining (KDD '24)*, Association for Computing Machinery (ACM), Barcelona, Spain, pp.6491-6501, Aug. 2024.
DOI: <https://doi.org/10.1145/3637528.3671470>
- [32] O. Ovadia, M. Brief, M. Mishaelli, O. Elisha, "Fine-Tuning or Retrieval? Comparing Knowledge Injection in LLMs", *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP 2024)*, Association for Computational Linguistics, Miami, Florida, USA, pp.237-250, Nov. 2024.
DOI: <https://doi.org/10.18653/v1/2024.emnlp-main.15>
- [33] H. Soudani, E. Kanoulas, F. Hasibi, "Fine Tuning vs. Retrieval Augmented Generation for Less Popular Knowledge", *Proceedings of the 2024 Annual International ACM SIGIR Conference on Research and Development in Information Retrieval in the Asia Pacific Region (SIGIR-AP 2024)*, Association for Computing Machinery (ACM), Tokyo, Japan, pp.12-22, Dec. 2024.
DOI: <https://doi.org/10.1145/3673791.3698415>
- [34] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, et al., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks", *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, Curran Associates, Inc., Vancouver, Canada, No.793, pp.9459-9474, Dec. 2020.
- [35] X. Ma, Y. Gong, P. He, H. Zhao, N. Duan, "Query Rewriting for Retrieval-Augmented Large Language Models", *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP 2023)*, Association for Computational Linguistics, Singapore, pp.5303-5315, Dec. 2023.
DOI: <https://doi.org/10.18653/v1/2023.emnlp-main.322>
- [36] W. Peng, G. Li, Y. Jiang, Z. Wang, D. Ou, et al., "Large Language Model based Long-tail Query Rewriting in Taobao Search", *Companion Proceedings of the ACM Web Conference 2024 (WWW '24)*, Association for Computing Machinery (ACM), Singapore, pp. 20-28, May. 2024.
DOI: <https://doi.org/10.1145/3589335.3648298>
- [37] V. Blagojevic, Enhancing RAG Pipelines in Haystack: Introducing DiversityRanker and LostInTheMiddle Ranker, Towards Data Science, c2023 [cited 2023 Aug 8], Available From: <https://towardsdatascience.com/enhancing-rag-pipelines-in-haystack-45f14e2bc9f5/> (accessed Jan. 16, 2026)
- [38] H. W. Jang, There is a way to deploy Defense-specific ChatGPT across the entire military, Skyedaily, c2024 [cited 2024 July 4], Available From: https://www.skyedaily.com/news/news_view.html?ID=238322 (accessed Jan. 16, 2026)
- [39] V. G. Goecks, N. Waytowich, R. Bookman, C. Kenney, COA-GPT 2.0: An Agentic AI Planning Tool for Accelerating the Military Decision-Making Process, Under Review, 2025
- [40] D. C. Ruiz, J. Sell, "Fine-Tuning and Evaluating Open-Source Large Language Models for the Army Domain", arXiv preprint arXiv.2410.20297, Oct. 2024.
DOI: <https://doi.org/10.48550/arXiv.2410.20297>
- [41] S. Es, J. James, L. Espinosa-Anke, S. Schockaert, "RAGAs: Automated Evaluation of Retrieval Augmented Generation", *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations (EA CL 2024)*, Association for Computational Linguistics, St. Julians, Malta, pp. 150-158, Mar. 2024.
DOI: <https://doi.org/10.18653/v1/2024.eacl-demo.16>
- [42] M. K. Z. kizi, Y. Suh, "Design and Performance Evaluation of LLM-Based RAG Pipelines for Chatbot Services in International Student Admissions", *Electronics*. MDPI, Vol.14, No.15, pp.3095, Aug. 2025.
DOI: <https://doi.org/10.3390/electronics14153095>

고 동 희(Dong-Hee Koh)

[정회원]



- 2014년 5월 : Western Illinois University 지리학과 (지리학 석사)
- 2020년 8월 : University of Tennessee, Knoxville 지리학과 (지리학 박사)
- 2023년 3월 ~ 현재 : ㈜아레스 M&S AI R&D팀 책임연구원

<관심분야>

자연어 처리, 인공지능, 통계적 모델링, 지리 공간 분석

이 창 수(Chang-Su Lee)

[정회원]



- 2022년 8월 : 한밭대학교 정보통신공학부 (학사)
- 2023년 10월 ~ 현재 : ㈜아레스 M&S AI R&D팀 연구원

<관심분야>

인공지능, 빅데이터, 데이터사이언스, 소프트웨어공학

박 정 준(Jung-Jun Park)

[정회원]



- 1998년 2월 ~ 2003년 3월 : 육군 전투지휘훈련단 재직
- 2003년 3월 ~ 2009년 7월 : 포스데이터 국방사업단(부장)
- 2018년 1월 ~ 2022년 3월 : LIGNEX1 전장관리사업단장
- 2022년 4월 ~ 현재 : ㈜아레스 총괄본부장

<관심분야>

국방전장관리(C4ISR, M&S), AI & M&S 응용체계, 국방M&S 디지털트윈 융합

김 진 원(Jin-Won Kim)

[정회원]



- 1984년 2월 : 동국대학교 전산학 (학사)
- 1993년 12월 : 국방대학교 전산학 (석사)
- 1996년 8월 ~ 1999년 7월 : 가천대학교 전산학과 강의
- 2003년 6월 : Stanford Center for Professional Development (Emotional Intelligence 전공)
- 2008년 8월 ~ 현재 : ㈜아레스 대표이사

<관심분야>

AI, VR, XR, Military Technologies