

Engineered Dossier

전술적 청사진: 폐쇄망 환경을 위한 SLLM-Advanced RAG 융합 아키텍처

군사 교리 도메인에서의 환각 제어 및
온프레미스 AI 구축 최적화 방안

[On-Premise]




[Military Doctrine]



[Zero-Hallucination]




[GPT-20B]



**자원 제약
(Hardware Limits)**

제한된 GPU 인프라
(A6000 단일 환경 수준)



**절대적 보안성
(Absolute Security)**

외부 연결 불가, 온프레미스 폐쇄망 필수

**무결점 정확성
(Zero Margin for Error)**

군사 교리/전술 지식의
환각(Hallucination) 절대 불가


거대 언어 모델(LLM)은 이 세가지 조건을 동시에 충족할 수 없음. 정확성과 보안성을 보장할 수 있는 대안 필요

체급의 역설: 거대 모델 vs. 경량 특화 모델

Heavyweights (초거대 모델) GPT-120B, Llama-405B	Lightweights (경량 모델) GPT-20B, Llama-8B
운용 환경 (On-Premise Viability) 클라우드 의존 / 대규모 클러스터 필수	단일 A6000 GPU 구동 가능 (vLLM 최적화)
도입 및 유지 비용 (Hardware Cost) 천문학적 인프라 유지비	극대화된 자원 효율성 및 경제성
전문 도메인 정확도 (Domain Accuracy) 파라미터가 커도 특수 군사 교리에서 여전히 환각(Hallucination) 발생	RAG 결합 시 특수 도메인에서 대형 모델 압도


매개변수(Parameter)의 크기가 전술적 정확도를 보장하지 않음.

전술적 아키텍처: SLLM과 Advanced RAG의 융합



파인튜닝(Fine-tuning)의 막대한 자원 소모 없이,
Advanced RAG의 정보 주입만으로 도메인 특화 성능을 극대화할 수 있음

작전 데이터: 북한군 전술(North Korean Tactics) 교리



데이터 출처 (Source)

미 육군 공개 아카이브 기밀 해제 교리
(총 342쪽, 9개 장)


데이터 구축 (Generation)

DeepEval 프레임워크 기반
LLM-RAGOps 합성 데이터 구축


테스트 시나리오 (Scenarios)

69개의 고난도 전술적 질의응답 시나리오
(추론 및 다중 문맥 요구)

핵심: 단순 키워드 매칭이 아닌,
전술적 의도와 교리적 정합성을
검증하는 하드코어 테스트베드.



1단계: RAG 부재 시의 치명적 결함 (No RAG)



의도 파악 (Answer Relevancy)
0.91 ~ 0.94

모델들은 질문의 '의도'는 완벽히 파악하며
그렇듯한 답변을 생성함.



사실 부합성 (Faithfulness)
0.212 ~ 0.433





심각한 환각(Hallucination) 발생 구간

**전략적 통찰: 초거대 모델(Llama-405B)조차 군사 특수 지식에서는 환각을 피할 수 없음.
외부 지식의 개입 없이는 절대 무기체계에 적용할 수 없음.**


정확성의 척도: 표면적 유사도를 넘어 논리적 완결성으로

전통적 NLP 지표 (단순 텍스트 일치율)




한계: 의미가 같아도 교리적 표현이 다르면
기계적으로 페널티를 부여합니다.

LLM 심판관 (전술적 맥락 분석)



GPT-4.1 기반 정성/정량 평가.
측정 지표: 정확성(Accuracy),
완전성(Completeness), 논리/추론(Coherence),
전문 용어 정밀성(Precision)

2단계: Naive-RAG의 개입과 환각의 억제



데이터 요약 (Data Points)

- 사실 부합성 급상승: Faithfulness 지표가 0.212에서 최대 0.706으로 도약.
- 최고 종합 성능: Llama-8B (0.772), GPT-20B (0.765).
- 정성적 평가: 정확성(Accuracy)과 완전성(Completeness)에서 No-RAG 대비 압도적 개선 확인.

전략적 통찰: 기본 RAG만으로도 암묵적 추론(환각)을 명시적 근거 기반 답변으로 개선할 수 있음을 실험 결과 확인

Naive-RAG의 전술적 한계: '문맥 재현율(Recall)'의 벽



현재의 문제점 (The Bottleneck)

- Context Precision (검색 정밀도): 0.824 ~ 0.877 (매우 우수함)
- Context Recall (검색 포괄성): 0.526 ~ 0.791 (치명적 약점)


원인 분석

소규모 모델들은 검색 전략이 지나치게 보수적입니다. 핵심 단어는 완벽히 찾지만, 교리의 광범위한 "전술적 배경"을 놓쳐 파편화된 정보만을 제공.


다음 단계: 단순 검색을 넘어선
Advanced RAG 기술 전개

3단계 돌파구 (인덱스 최적화): Parent-Child 구조

The Engineered Dossier




성능 비교 (Performance Comparison)



성능 지표 (Results)

- 🎯 - Context Precision: 0.907 (최고 정밀도 방어)
- 🛡️ - Context Recall: 0.813 (문맥 유실 완벽 차단)
- ⚖️ - F1 Score: 0.860 (검색 품질의 완벽한 균형)

전술적 시야 확장: 쿼리 확장(Query Expansion)




메커니즘 (Mechanism)

군사 질의는 복잡하고 암묵적일 수 있음. 쿼리를 여러 개의 암묵적인 Sub-queries로 분해하여 다변화된 벡터스토어 검색 통한 검색 품질 향상

전술적 효과 (Impact)

- 단일 쿼리로 포착하기 어려운 다양한 전술적 관점을 검색 단계에서 반영.
- Parent-Child 구조와 결합 시, 근거 단절을 최소화하고 가장 풍부한 컨텍스트를 도출해 냄.

정보의 정제: 상호 순위 융합 (RRF 후처리)



메커니즘 (Mechanism)

다중 쿼리로 검색된 방대한 검색 결과를 RRF 점수 기반으로 재정렬(Re-ranking). 중복을 제거하고 가장 핵심적인 문맥만을 선별하여 LLM에 전달.

전략적 가치 (Strategic Value)


입력 토큰(Token) 수를 획기적으로 감소시켜, A6000 단일 GPU 환경에서도 추론 지연 시간(Latency)을 최소화

진화의 궤적: No-RAG에서 Advanced RAG까지




결론: 단계적인 구조 고도화가 파라미터 증량보다 훨씬 더 높은 ROI(투자 대비 효율)를 창출할 수 있음.

최적의 전술 방정식: The Winning Formula



= 0.846 Overall Score (최고 성능 달성)


Performance Hierarchy



통계적 검증 (Statistical Validation)

- 부트스트랩(N=1,000) 95% 신뢰구간 검증 완료.
- 초거대 모델 Llama-405B의 성능(0.680)을 압도적으로 상회.
- 가장 효율적인 20B 체급 엔진과 가장 고도화된 정보 검색 기법의 완벽한 결합.

실전 배치를 위한 전략적 가이드라인



1. 인프라 최적화 (Hardware)

천문학적 클라우드 비용 불필요.
단일 A6000 GPU 노드에서
고성능 군사 AI 운용 보장.



2. 완벽한 보안 통제 (Security)

데이터 외부 유출 제로(0).
100% 온프레미스 폐쇄망 내에서
자체적인 지식 생태계 구축.



3. 신뢰성의 확보 (Accuracy)

Advanced RAG 파이프라인을 통한
환각 제어. 지휘관 결심을 보조할 수
있는 교리적 팩트 기반의 시스템.

대규모 파라미터 대신 RAG와 sLLM 결합을 선택,
보안과 비용 효율을 극대화한 폐쇄망 솔루션 구축 가능

