

RAG(Retrieval-Augmented Generation) 시스템에 여러 고급 인덱싱 기법을 적용하면, 검색 결과에 상당한 차이가 발생할 수 있습니다. 각 기법은 특정 시나리오에 최적화되어 있어, 서로 다른 유형의 질문에 대해 더 정확하고 관련성 높은 정보를 찾아낼 수 있도록 돕기 때문입니다.

1. 검색 결과의 차이점

Parent-Child Document Retriever (부모-자식 문서 검색기)

- 어떻게 다른가: 이 기법은 작은 청크(자식)를 검색하여 관련성을 판단한 후, 해당 청크가 속한 더 큰 문서(부모) 전체를 검색 결과로 반환합니다.
- 결과 차이: 자세한 내용과 넓은 문맥을 동시에 제공합니다. 사용자의 질문이 특정 사실을 묻는 것이더라도, 그 사실이 포함된 전체 문서를 가져와서 답변의 맥락을 풍부하게 만들 수 있습니다. 반면, 일반적인 검색 기법은 단일 청크만 반환하여 맥락이 부족할 수 있습니다. 예를 들어, "2024년 1분기 애플의 매출액은 얼마인가요?"라는 질문에 대해, 자식 청크가 해당 매출액을 포함하더라도 부모 문서인 '2024년 1분기 애플 실적 보고서' 전체를 제공하여 더 깊이 있는 답변을 생성할 수 있습니다.

Summary Document Retriever (요약 문서 검색기)

- 어떻게 다른가: 이 기법은 긴 문서의 요약본을 인덱싱하고, 검색 시 사용자의 질문과 요약본을 비교하여 관련 문서를 찾습니다.
- 결과 차이: 전반적인 주제나 높은 수준의 질문에 더 효과적입니다. 문서의 핵심 내용을 빠르게 파악할 수 있어, "최근 AI 기술 동향에 대해 알려주세요"와 같은 넓은 범위의 질문에 적합합니다. 반면, 아주 구체적인 사실(예: 특정 인물의 생년월일)을 묻는 질문에는 정확도가 떨어질 수 있습니다.

Hypothetical Questions Retriever (가상 질문 검색기)

- 어떻게 다른가: 이 기법은 문서의 내용으로부터 ****가상의 질문-답변 쌍(HyDE)****를 생성하여 이를 인덱싱합니다. 사용자의 질문이 주어지면, 시스템은 이 질문과 가장 유사한 가상 질문을 찾고, 그에 해당하는 문서를 반환합니다.
- 결과 차이: 자연어의 다양한 표현을 포괄하여 검색 정확도를 높입니다. 사용자가 질문을 어떻게 표현하든, 시스템은 이미 다양한 방식으로 변형된 가상 질문을 가지고 있어 더 정확한 문서를 찾을 가능성이 높습니다. 예를 들어, "COVID-19 백신의 부작용"을 묻는 질문이 "코로나 주사 맞고 열이 났어요. 괜찮나요?"와 같이 일상적인 언어로 표현되더라도, 이와 관련된 가상 질문을 통해 적절한 정보를 찾아낼 수 있습니다.

Granular Chunk Expansion (세분화된 청크 확장)

- 어떻게 다른가: 이 기법은 검색된 작은 청크를 기반으로, 인접한 문맥(예: 앞뒤 문장)을 함께

확장하여 LLM에 전달합니다.

- **결과 차이:** 검색 결과의 관련성을 유지하면서도 충분한 문맥 정보를 제공합니다.
Parent-Child 기법이 전체 문서를 가져오는 것과는 다르게, 이 기법은 필요한 만큼만 문맥을 확장하여 토큰 낭비를 줄이고 효율성을 높입니다. 예를 들어, "김철수 박사의 연구 주제"에 대한 질문에, 관련 문장이 있는 청크를 찾은 후, 그 앞뒤 문장을 추가하여 "김 박사의 주요 연구 분야는 인공지능 윤리이며, 그는 이 분야에서 여러 논문을 발표했습니다"와 같이 더 완전한 답변을 생성할 수 있습니다.
-

2. 결론

각 기법은 고유한 장단점을 가지고 있으며, 질문의 유형과 의도에 따라 다른 검색 결과를 도출합니다. 따라서, 여러 기법을 혼합하여 사용하는 하이브리드 **RAG** 시스템을 구축하면, 다양한 사용자 질문에 대해 더 견고하고 정확한 답변을 생성할 수 있습니다. 예를 들어, **HyDE**를 사용하여 검색의 초기 정확도를 높이고, **Granular Chunk Expansion**을 통해 LLM에 전달되는 정보를 최적화하는 방식입니다. 이러한 고급 인덱싱 기법들은 단순한 키워드 매칭을 넘어서, 질문의 의미를 더 깊이 이해하고 적절한 문맥을 제공함으로써 검색 결과의 품질을 혁신적으로 향상시킵니다.